Tarea 2: Health Landscape -- ENO + GRD

Points: 10
Released: Thursday, March 26, 2026
Due: Thursday, April 16, 2026 (before class)
Submission: Canvas -- PDF export of your notebook + link to your GitHub repo

---

Members: Javier Becerra Muñoz & Jose Pino Muñoz
Comunas: La Granja, Macul, San Ramón
Group: 1

Goal

Build a health portrait of your assigned comunas using two complementary datasets: **ENO** (notifiable-disease surveillance, 2007--2024) and **GRD** (hospital discharge records, 2022--2024). In Tarea 0 you proved you could open and inspect each dataset; in Tarea 1 you built a demographic baseline from the Census. Now you go deeper into the health data: cleaning messy categorical variables, computing rates, building disease profiles by nationality, and producing **comuna-level summary tables** that you will merge with the Census summary in Tarea 3.

By the end of this assignment you should be comfortable with:

- Cleaning real-world categorical data (inconsistent coding, anonymized values, missing categories)
- Computing disease notification rates and hospitalization rates
- Working with ICD-10 codes and diagnostic chapter groupings
- Comparing health profiles between Chilean and foreign-born populations
- Building choropleth maps of health indicators

Part A: ENO -- Notifiable Diseases (5 pts)

A.0 Data Loading & Cleaning (1 pt)

A.0.1 Load the ENO dataset

Load `materials/eno/20241218_base_eno_final.csv` (semicolon-delimited, UTF-8-sig encoding). Select only the columns you will need:

```
import pandas as pd
# 1. Definimos las columnas solicitadas
eno_cols = [
"ENO", "anho_notificacion", "region", "codigo_comuna_residencia",
"nacionalidad", "sexo", "grupo_edad", "nombre_instruccion",
"cie_10_diagnostico", "diagnostico", "pais_contagio"
]
# 2. Cargamos los datos (Asegúrate de que la ruta del archivo sea la correcta en tu entorno)
eno = pd.read_csv("../Datasets/ENO/20241218_base_eno_final.csv",
sep=";", encoding="utf-8-sig", usecols=eno_cols)
# 3. Reportamos eno.shape
print("--- TAMAÑO DEL DATASET (eno.shape) ---")
print(f"Filas: {eno.shape[0]:,}")
print(f"Columnas: {eno.shape[1]}")
print("\n")
# 4. Reportamos eno.info()
print("--- INFORMACIÓN DE LAS COLUMNAS (eno.info()) ---")
eno.info()
```

```
--- TAMAÑO DEL DATASET (eno.shape) ---
Filas: 333,300
Columnas: 11


--- INFORMACIÓN DE LAS COLUMNAS (eno.info()) ---
<class 'pandas.DataFrame'>
RangeIndex: 333300 entries, 0 to 333299
Data columns (total 11 columns):
 #   Column                   Non-Null Count   Dtype
---  ------                   --------------   -----
 0   region                   333300 non-null  str
 1   nacionalidad             333300 non-null  str
 2   cie_10_diagnostico       333300 non-null  str
 3   diagnostico              333300 non-null  str
 4   anho_notificacion        333300 non-null  int64
 5   ENO                      333300 non-null  str
 6   nombre_instruccion       333300 non-null  str
 7   pais_contagio            333300 non-null  str
 8   sexo                     333300 non-null  str
 9   grupo_edad               333300 non-null  str
 10  codigo_comuna_residencia 333300 non-null  str
dtypes: int64(1), str(10)
memory usage: 28.0 MB
```

Report `eno.shape` and `eno.info()`.

A.0.2 Filter to your comunas

The comuna column is `codigo_comuna_residencia`. It contains **numeric codes as strings** (e.g., `"13101"` for Santiago), but a large fraction of rows are anonymized as `"*****"`.

Filter to your assigned comunas:

```
# 1. Aseguramos la lista de comunas (La Granja, Macul, San Ramón)
# y las convertimos a texto (string) tal como pide la instrucción
MY_COMUNAS = [13111, 13118, 13131]
my_comunas_str = [str(c) for c in MY_COMUNAS]

# 2. Calculamos el impacto de la anonimización en el dataset COMPLETO.
filas_anonimizadas = (eno["codigo_comuna_residencia"] == "*****").sum() # Contamos cuántas filas tienen la comuna de residencia anonimizadas (*****)
total_filas = len(eno) # Contamos el número total de filas en el dataset para entender la escala del dataset completo.
porcentaje_anonimizado = (filas_anonimizadas / total_filas) * 100 # Calculamos el porcentaje de filas que fueron anonimizadas para entender el impacto de la anonimización en
print("--- REPORTE DE ANONIMIZACIÓN (LIMITACIÓN DE DATOS) ---") # Reportamos el número total de filas en el dataset, cuántas filas tienen la comuna de residencia anonimizadas
print(f"Filas totales en ENO: {total_filas:,}") # Reportamos el número total de filas en el dataset para entender la escala del dataset completo.
print(f"Filas con comuna '*****': {filas_anonimizadas:,}") # Reportamos cuántas filas tienen la comuna de residencia anonimizadas (*****), para entender el impacto de la anor
print(f"Porcentaje de datos anonimizados: {porcentaje_anonimizado:.1f}%\n") # Reportamos el porcentaje que esto representa del total para entender el impacto de la anonimizac

# 3. Filtramos solo a tus comunas asignadas
# Utilizamos .copy() para no tener advertencias de Pandas más adelante
```

```
eno_com = eno[eno["codigo_comuna_residencia"].isin(my_comunas_str)].copy() # Filtramos el dataset para quedarnos solo con las filas donde la comuna de residencia esté en nues
print("--- RESULTADO DEL FILTRO ---")
print(f"Rows in my comunas (La Granja, Macul, San Ramón): {len(eno_com):,}\n")
```

```
--- REPORTE DE ANONIMIZACIÓN (LIMITACIÓN DE DATOS) ---
Filas totales en ENO: 333,300
Filas con comuna '*****': 148,217
Porcentaje de datos anonimizados: 44.5%

--- RESULTADO DEL FILTRO ---
Rows in my comunas (La Granja, Macul, San Ramón): 2,520
```

Important: report how many rows in the full ENO dataset have `codigo_comuna_residencia == "*****"` (anonymized). This is a data limitation you should acknowledge in your analysis. You cannot recover these rows, so your comuna-level counts will be **undercounts** of the true notification burden.

A.0.3 Clean the nationality variable

The `nacionalidad` column has three values: `"Chile"`, `"Extranjero"`, and `"Desconocido"` (unknown). Report the distribution of `nacionalidad` in your filtered data.

For nationality-specific analyses, **exclude** rows where `nacionalidad == "Desconocido"`, but always report how many rows you are dropping. Do not silently discard them.

```
# 1. Calculamos la distribución exacta de la variable nacionalidad
distribucion_nac = eno_com["nacionalidad"].value_counts(dropna=False) # Contamos cuántas filas hay de cada nacionalidad en el dataset filtrado (solo comunas asignadas) para e
total_comunas = len(eno_com) # Contamos el número total de filas en el dataset filtrado (solo comunas asignadas) para entender la escala de nuestro subconjunto de datos y par

print("--- DISTRIBUCIÓN DE NACIONALIDAD (La Granja, Macul, San Ramón) ---") # Reportamos la distribución de la variable nacionalidad en el dataset filtrado (solo comunas asig
for nac, count in distribucion_nac.items():
    pct = (count / total_comunas) * 100 # Calculamos el porcentaje que representa cada categoría de nacionalidad respecto al total de filas en el dataset filtrado (solo comur
    print(f"{nac}: {count:,} ({pct:.1f}%)") # Reportamos el conteo de cada categoría de nacionalidad y su porcentaje respecto al total de filas en el dataset filtrado (solo c
print("\n")

# 2. Calculamos las filas que vamos a eliminar ("Desconocido")
filas_desconocido = (eno_com["nacionalidad"] == "Desconocido").sum() # Contamos cuántas filas tienen la categoría "Desconocido" en la variable nacionalidad en el dataset filt
porcentaje_perdido = (filas_desconocido / total_comunas) * 100 # Calculamos el porcentaje que representa la categoría "Desconocido" respecto al total de filas en el dataset f

print("--- REPORTE DE EXCLUSIÓN ('Desconocido') ---")
print(f"Registros totales antes del filtro: {total_comunas:,}") # Reportamos el número total de filas en el dataset filtrado (solo comunas asignadas) antes de eliminar la cat
print(f"Filas descartadas (Nacionalidad 'Desconocido'): {filas_desconocido:,}") # Reportamos cuántas filas tienen la categoría "Desconocido" en la variable nacionalidad en el
print(f"Fracción de datos descartados: {porcentaje_perdido:.1f}%") # Reportamos cuántas filas tienen la categoría "Desconocido" en la variable nacionalidad en el dataset filt

# 3. Creamos nuestro nuevo DataFrame, limpio solo con Chile y Extranjero
# Usamos "!=" para quedarnos con todo lo que NO sea "Desconocido"
eno_nac = eno_com[eno_com["nacionalidad"] != "Desconocido"].copy() # Creamos un nuevo DataFrame que contiene solo las filas donde la variable nacionalidad no es "Desconocido'

print(f"\nRegistros válidos para análisis de nacionalidad: {len(eno_nac):,}") # Reportamos el número de filas que quedan en nuestro nuevo DataFrame después de eliminar las fi
```

```
--- DISTRIBUCIÓN DE NACIONALIDAD (La Granja, Macul, San Ramón) ---
Chile: 1,218 (48.3%)
Desconocido: 1,030 (40.9%)
Extranjero: 272 (10.8%)


--- REPORTE DE EXCLUSIÓN ('Desconocido') ---
Registros totales antes del filtro: 2,520
Filas descartadas (Nacionalidad 'Desconocido'): 1,030
Fracción de datos descartados: 40.9%

Registros válidos para análisis de nacionalidad: 1,490
```

A.0.4 Report the time span

Show the range of `anho_notificacion` in your filtered data. How many notifications per year do your comunas have? Present as a simple table.

```
# 1. Calculamos el rango de años
primer_ano = eno_com["anho_notificacion"].min() # Calculamos el año más antiguo de notificación en el dataset filtrado (solo comunas asignadas) para entender desde cuándo ter
ultimo_ano = eno_com["anho_notificacion"].max() # Calculamos el año más reciente de notificación en el dataset filtrado (solo comunas asignadas) para entender hasta cuándo te

print("--- RANGO TEMPORAL ---")
print(f"Los datos abarcan desde el año {primer_ano} hasta el {ultimo_ano}.\n")

# 2. Contamos las notificaciones por año
# Usamos value_counts(), ordenamos por el año (sort_index) y lo convertimos en tabla
casos_por_ano = eno_com["anho_notificacion"].value_counts().sort_index().reset_index() # Calculamos el número de notificaciones por año en el dataset filtrado (solo comunas a

# Renombramos las columnas para que la tabla se entienda perfecto
casos_por_ano.columns = ["Año de Notificación", "Total de Casos"]

# 3. Imprimimos la tabla
print("--- NOTIFICACIONES POR AÑO (La Granja, Macul, San Ramón) ---")
print(casos_por_ano.to_string(index=False))
```

```
--- RANGO TEMPORAL ---
Los datos abarcan desde el año 2007 hasta el 2024.

--- NOTIFICACIONES POR AÑO (La Granja, Macul, San Ramón) ---
 Año de Notificación  Total de Casos
                2007            130
                2008            126
                2009             94
                2010            107
                2011            167
                2012            166
                2013            138
                2014            106
                2015            107
                2016             87
                2017            117
                2018            194
                2019            197
                2020            103
                2021            111
                2022            130
                2023            295
                2024            145
```

How many notifications per year do your comunas have?

El conjunto de datos analizado para las comunas de La Granja, Macul y San Ramón abarca un período de 18 años, iniciando en 2007 y culminando en 2024.

Al revisar la distribución anual de notificaciones (casos), se observan tres etapas claras en el comportamiento epidemiológico local:

- **Línea base histórica (2007 - 2019)**: Durante más de una década, las comunas mantuvieron una carga de notificaciones relativamente estable, oscilando entre 87 y 197 casos anuales.
- **El "Valle" Pandémico (2020 - 2022)**: Contraintuitivamente, los años más duros de la pandemia de COVID-19 muestran una baja en las notificaciones generales (cayendo a 103 casos en 2020). Esto es un fenómeno epidemiológico conocido: las cuarentenas, el distanciamiento social y la saturación de los centros médicos redujeron drásticamente la circulación y notificación de otras enfermedades tradicionales.
- **El rebrote o "Catch-up" (2023 - 2024)**: El año 2023 marca el máximo histórico absoluto de la serie con 295 notificaciones, lo que probablemente refleja un "efecto rebote" post-pandémico (personas retomando atenciones médicas postergadas o brotes de virus respiratorios tras el fin de las restricciones). Finalmente, el año 2024 muestra 145 casos, una cifra que debe interpretarse con cautela al tratarse de un año probablemente incompleto en la fecha de corte de la base de datos.

A.1 Notification Trends Over Time (1 pt)

A.1.1 Overall trend

Plot the **total number of notifications per year** in your comunas as a line chart (x-axis: year, y-axis: count). Annotate or comment on any visible jumps or drops (e.g., COVID-19 period effects on surveillance).

```
import matplotlib.pyplot as plt

# con las columnas "Año de Notificación" y "Total de Casos"
fig, ax = plt.subplots(figsize=(12, 6)) # Creamos un gráfico de barras con las columnas "Año de Notificación" y "Total de Casos" para visualizar la evolución de los casos a l

# Trazamos la línea
ax.plot(casos_por_ano["Año de Notificación"], casos_por_ano["Total de Casos"],
    marker='o', linestyle='-', color='#d62728', linewidth=2, markersize=8) # Configuramos el estilo de la línea para que sea más visualmente atractiva y fácil de interpretar.

# Configuración visual principal
ax.set_title('Tendencia de Notificaciones de Salud (2007 - 2024)\n(La Granja, Macul, San Ramón)', # Agregamos un título descriptivo al gráfico para que se entienda claramente
            fontweight='bold', fontsize=14)
ax.set_xlabel('Año de Notificación', fontsize=12)
ax.set_ylabel('Total de Casos Notificados', fontsize=12)

# Obligamos al eje X a mostrar todos los años (para evitar que se salte números)
ax.set_xticks(casos_por_ano["Año de Notificación"])
ax.tick_params(axis='x', rotation=45) # Rotamos las etiquetas del eje X para mejorar la legibilidad, especialmente si hay muchos años o si los números se superponen.

# Agregamos una grilla sutil de fondo
ax.grid(axis='both', linestyle='--', alpha=0.5)

# 1. Anotación de la caída por Pandemia (2020)
ax.annotate('Caída por Pandemia\n(Subnotificación / Cuarentenas)',
            xy=(2020, 103), # Punto al que apunta la flecha
            xytext=(2017, 20), # Posición del texto
            arrowprops=dict(facecolor='black', arrowstyle='->', lw=1.5), # Configuramos la flecha para que sea clara y visible, apuntando al año 2020 donde se observa la caíc
            fontsize=10, fontweight='bold', color='#333333')

# 2. Anotación del salto Post-Pandemia (2023)
ax.annotate('Máximo Histórico\n(Efecto "Catch-up")',
            xy=(2023, 295),  # Punto al que apunta la flecha (el año 2023, donde se observa un máximo histórico en las notificaciones, posiblemente debido a un efecto de "cat
            xytext=(2019, 270),  # Posición del texto para que quede cerca del punto pero sin superponerse, indicando que en 2023 se observa un máximo histórico en las notifi
            arrowprops=dict(facecolor='black', arrowstyle='->', lw=1.5), # Configuramos la flecha para que sea clara y visible, apuntando al año 2023 donde se observa el máxi
            fontsize=10, fontweight='bold', color='#333333')

# 3. Anotación de año incompleto (2024)
ax.annotate('Año Incompleto\n(Corte de datos)',
            xy=(2024, 145), # Punto al que apunta la flecha (el año 2024, que muestra una caída aparente en las notificaciones debido a que no se han registrado todos los cas
            xytext=(2025, 200), # Posicionamos el texto a la derecha del año 2024 para indicar que este año no tiene datos completos, lo que explica la aparente caída en las
            ha='center', # Alineamos el texto horizontalmente al centro para que quede bien posicionado respecto al punto de anotación.
            arrowprops=dict(facecolor='grey', arrowstyle='->', lw=1), # Configuramos la flecha para que sea clara pero menos prominente, apuntando al año 2024 donde se observ
            fontsize=9, color='grey', style='italic') # Configuramos el estilo del texto para que sea menos prominente, indicando que el año 2024 no tiene datos completos, lo

# Limpiamos los bordes
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)

# Aseguramos que nada quede cortado
plt.tight_layout()
plt.show()
```

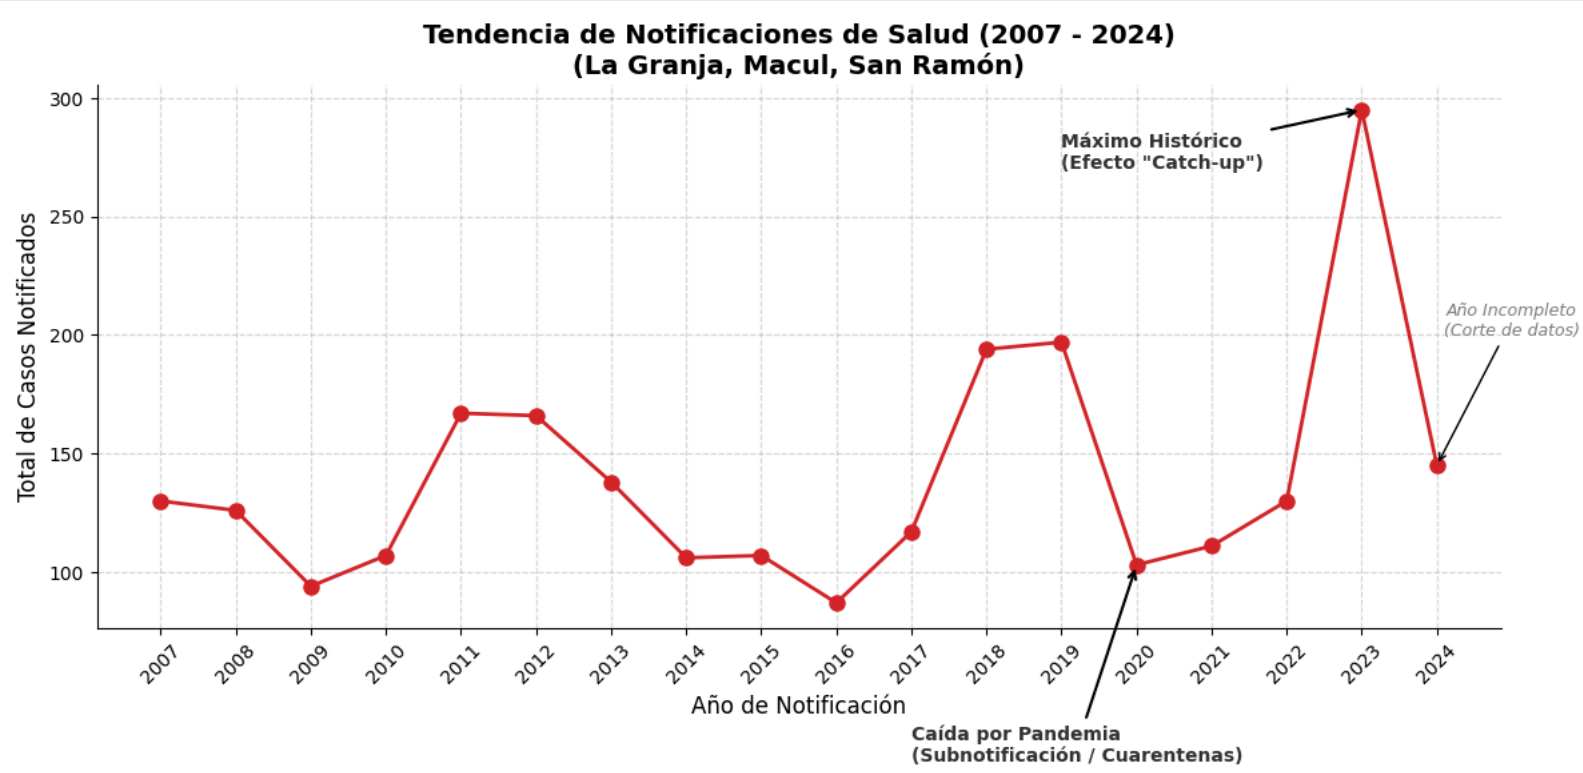

A.1.2 Trend by nationality

On the same plot (or a faceted version), break the trend down by `nacionalidad` (Chilean vs. Foreign, excluding "Desconocido").
Comment: has the share of foreign-national notifications changed over time?

```
# 1. Agrupamos por año y nacionalidad, y contamos los casos
# .unstack() convierte las nacionalidades en columnas para poder graficar dos líneas separadas
# fill_value=0 asegura que si un año no hay extranjeros, ponga 0 en vez de error
tendencia_nac = eno_nac.groupby(['anho_notificacion', 'nacionalidad']).size().unstack(fill_value=0)
```

```
# 2. Creamos la figura
fig, ax = plt.subplots(figsize=(12, 6))

# 3. Dibujamos las líneas (le damos colores distintos para que se entienda bien)
# Asumiendo que las columnas se llaman "Chile" y "Extranjero"
color_dict = {'Chile': '#1f77b4', 'Extranjero': '#ff7f0e'}

for col in tendencia_nac.columns:
    ax.plot(tendencia_nac.index, tendencia_nac[col], # Trazamos una línea para cada nacionalidad usando el índice (años) y los valores de cada nacionalidad, con un estilo cla
            marker='o', linestyle='-', linewidth=2, markersize=6, # Configuramos el estilo de las líneas para que sean claras y fáciles de interpretar, con marcadores en cada
            label=col, color=color_dict.get(col, '#2ca02c')) # Usamos un diccionario de colores para asignar colores específicos a "Chile" y "Extranjero", y un color por defe

# 4. Configuración visual
ax.set_title('Tendencia de Notificaciones por Nacionalidad (2007 - 2024)\n(La Granja, Macul, San Ramón)',
             fontweight='bold', fontsize=14) # Agregamos un título descriptivo al gráfico para que se entienda claramente qué información se está mostrando, incluyendo el rar
ax.set_xlabel('Año de Notificación', fontsize=12) # Agregamos una etiqueta al eje X para indicar que representa el año de notificación, con un tamaño de fuente adecuado para
ax.set_ylabel('Total de Casos Notificados', fontsize=12) # Agregamos una etiqueta al eje Y para indicar que representa el total de casos notificados, con un tamaño de fuente

# Forzamos los años en el eje X
ax.set_xticks(tendencia_nac.index)
ax.tick_params(axis='x', rotation=45) # Rotamos las etiquetas del eje X para que se lean mejor

# Agregamos la leyenda y la grilla
ax.legend(title='Nacionalidad', frameon=True)
ax.grid(axis='both', linestyle='--', alpha=0.5) # Agregamos una grilla para facilitar la lectura de los valores

# Limpiamos los bordes
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)

plt.tight_layout()
plt.show()
```

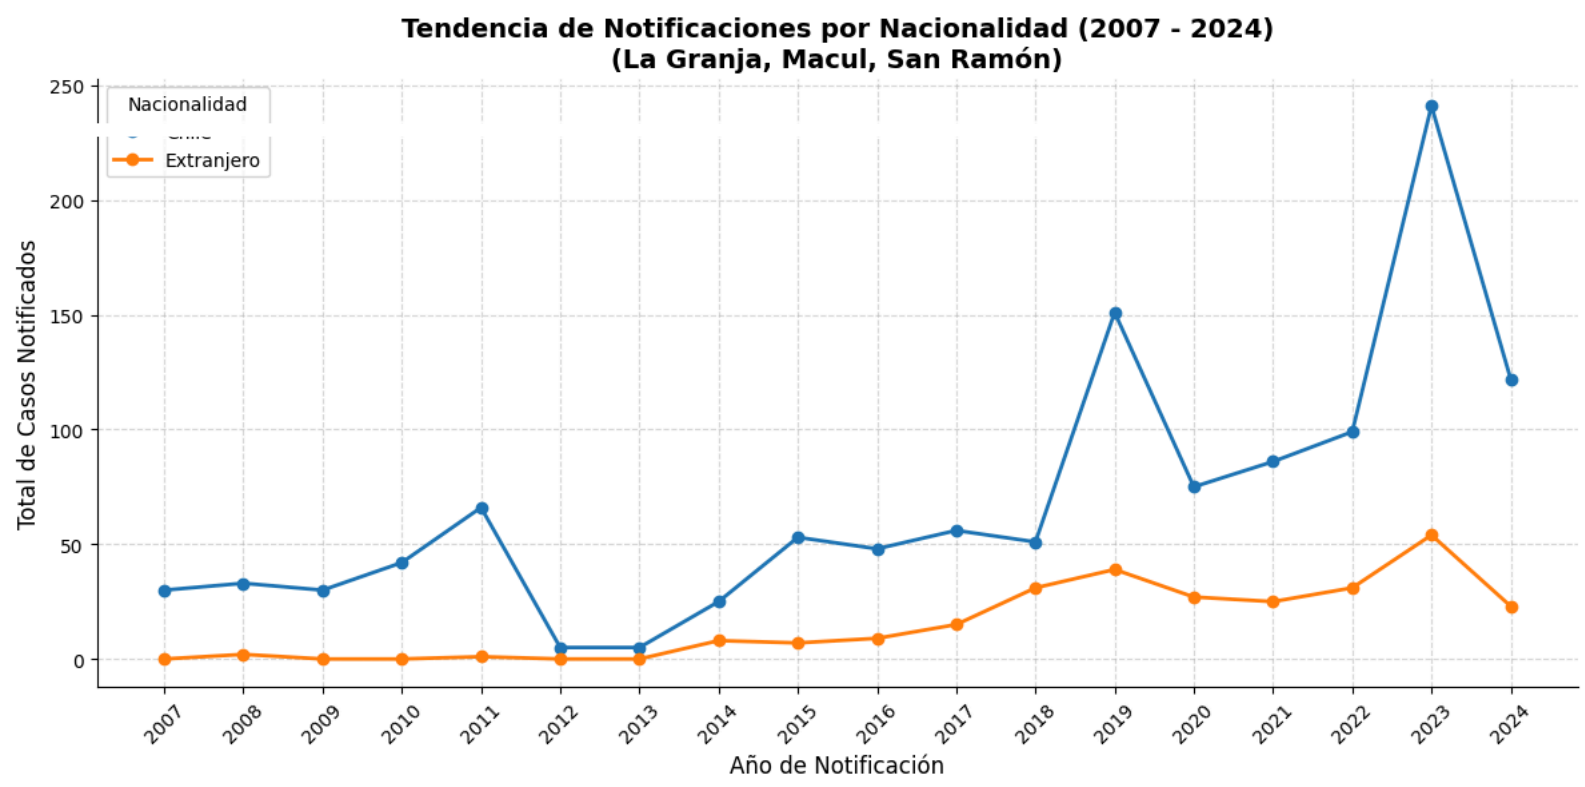

Has the share of foreign-national notifications changed over time?

Al analizar la evolución temporal, es evidente que la participación o cuota (share) de notificaciones correspondientes a ciudadanos extranjeros ha experimentado un cambio estructural profundo.

Durante la primera década de la serie temporal (2007-2016), la proporción de casos de pacientes extranjeros era prácticamente marginal, representando una fracción mínima y casi imperceptible del total de notificaciones de salud en estas comunas. Sin embargo, a partir del período 2017-2018, la participación relativa de la población extranjera en las estadísticas del ENO comienza a escalar de manera acelerada y sostenida.

Este drástico cambio en la proporción no es un fenómeno clínico aislado tipo covid, sino que es el reflejo epidemiológico directo de la transformación demográfica documentada a través de los datos del Censo(lo cual pudimos comprobar respecto de la tarea nª1). A medida que se consolidaba el boom migratorio en La Granja, Macul y San Ramón en los años recientes, la población extranjera pasó de tener una presencia estadística nula a absorber una cuota históricamente inédita de las atenciones y notificaciones del sistema de vigilancia local en el período 2023-2024

A.2 Disease Profiles (1.5 pts)

A.2.1 Top diseases overall

Show the **top 10 notified diseases** (`ENO` column) in your comunas across all years. Present as a horizontal bar chart.

```
# 1. Contamos las frecuencias de la columna 'ENO' y sacamos el Top 10
top10_enfermedades = eno_com['ENO'].value_counts().head(10)

# 2. Ordenamos de menor a mayor para que el más grande quede arriba en el gráfico
top10_enfermedades = top10_enfermedades.sort_values(ascending=True)

# 3. Creamos la figura y el gráfico de barras horizontales
fig, ax = plt.subplots(figsize=(12, 7))

# Usamos un color azul clásico para temas de salud
barras = top10_enfermedades.plot(kind='barh', color='#1f77b4', edgecolor='white', ax=ax)

# 4. Configuración visual
ax.set_title('Top 10 Enfermedades de Notificación Obligatoria (2007 - 2024)\n(La Granja, Macul, San Ramón)',
             fontweight='bold', fontsize=14)
ax.set_xlabel('Cantidad Total de Notificaciones', fontsize=12)
ax.set_ylabel('Enfermedad (Categoría ENO)', fontsize=12)
ax.grid(axis='x', linestyle='--', alpha=0.7)

# 5. Agregamos el número exacto a la derecha de cada barra
for i, v in enumerate(top10_enfermedades):
    # Sumamos un pequeño margen (max() * 0.01) para que el texto no quede pegado a la barra
    margen = top10_enfermedades.max() * 0.01
    ax.text(v + margen, i, f"{int(v):,}", va='center', fontweight='bold', color='#333333')

# Limpiamos los bordes
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)
```

```
# Aseguramos que los nombres largos de las enfermedades no se corten
plt.tight_layout()
plt.show()
```

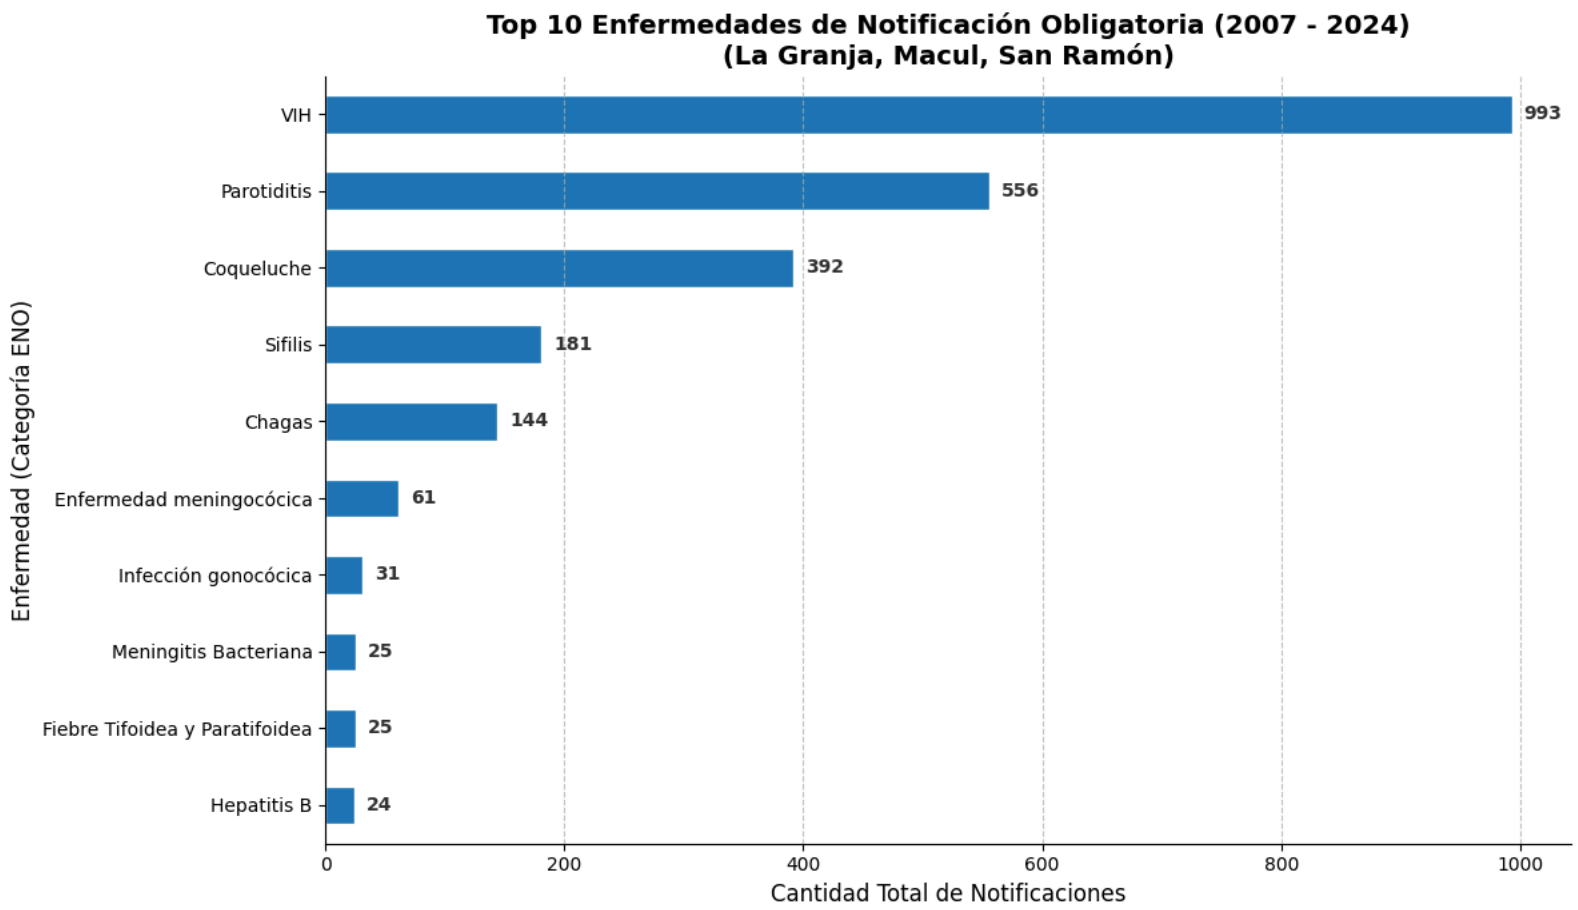

A.2.2 Disease profiles by nationality

For each of the top 5 diseases, compute the **share of Chilean vs. Foreign notifications** (excluding "Desconocido"). Present as a grouped or stacked bar chart.

Comment: are there diseases where foreign nationals are over-represented relative to their share of the local population? Use your Tarea 1 `pct_foreign` to contextualize.

```
# 1. Filtramos las nacionalidades válidas (excluyendo Desconocido)
# Usamos el dataframe 'eno_com' que ya filtramos por tus comunas anteriormente
eno_nac = eno_com[eno_com["nacionalidad"] != "Desconocido"].copy()

# 2. Identificamos las Top 5 enfermedades generales
top5_diseases = eno_nac['ENO'].value_counts().head(5).index.tolist()
df_top5 = eno_nac[eno_nac['ENO'].isin(top5_diseases)].copy()

# 3. Calculamos la proporción (share) por nacionalidad
# normalize='index' hace que cada barra sume 100%
share_table = pd.crosstab(df_top5['ENO'], df_top5['nacionalidad'], normalize='index') * 100

# Ordenamos para que la enfermedad más frecuente esté arriba
share_table = share_table.loc[top5_diseases[::-1]]

# 4. Generamos el gráfico de barras apiladas
fig, ax = plt.subplots(figsize=(12, 7))
colores = ['#1f77b4', '#ff7f0e'] # Azul (Chile), Naranja (Extranjero)
share_table.plot(kind='barh', stacked=True, color=colores, edgecolor='white', ax=ax)

# Configuración visual
ax.set_title('Perfil por Nacionalidad: Top 5 Enfermedades (ENO)\nContextualizado con Población Censo 2024',
             fontweight='bold', fontsize=14)
ax.set_xlabel('Proporción de Casos (%)', fontsize=12)
ax.set_ylabel('Enfermedad', fontsize=12)
ax.legend(title='Nacionalidad', bbox_to_anchor=(1.0, 1), loc='upper left')

# Agregamos etiquetas de porcentaje dentro de las barras
for c in ax.containers:
    ax.bar_label(c, fmt='%.1f%%', label_type='center', color='white', fontweight='bold')

# Línea de referencia: Marcamos el ~10% que es el promedio de extranjeros en tus comunas
# Esto ayuda visualmente a ver la "sobrerepresentación"
ax.axvline(x=90, color='red', linestyle='--', alpha=0.6, label='Umbral Poblacional (Referencia)')
plt.tight_layout()
plt.show()

# Imprimimos la tabla para el análisis textual
print("--- TABLA DE PARTICIPACIÓN POR ENFERMEDAD ---")
print(share_table)
```

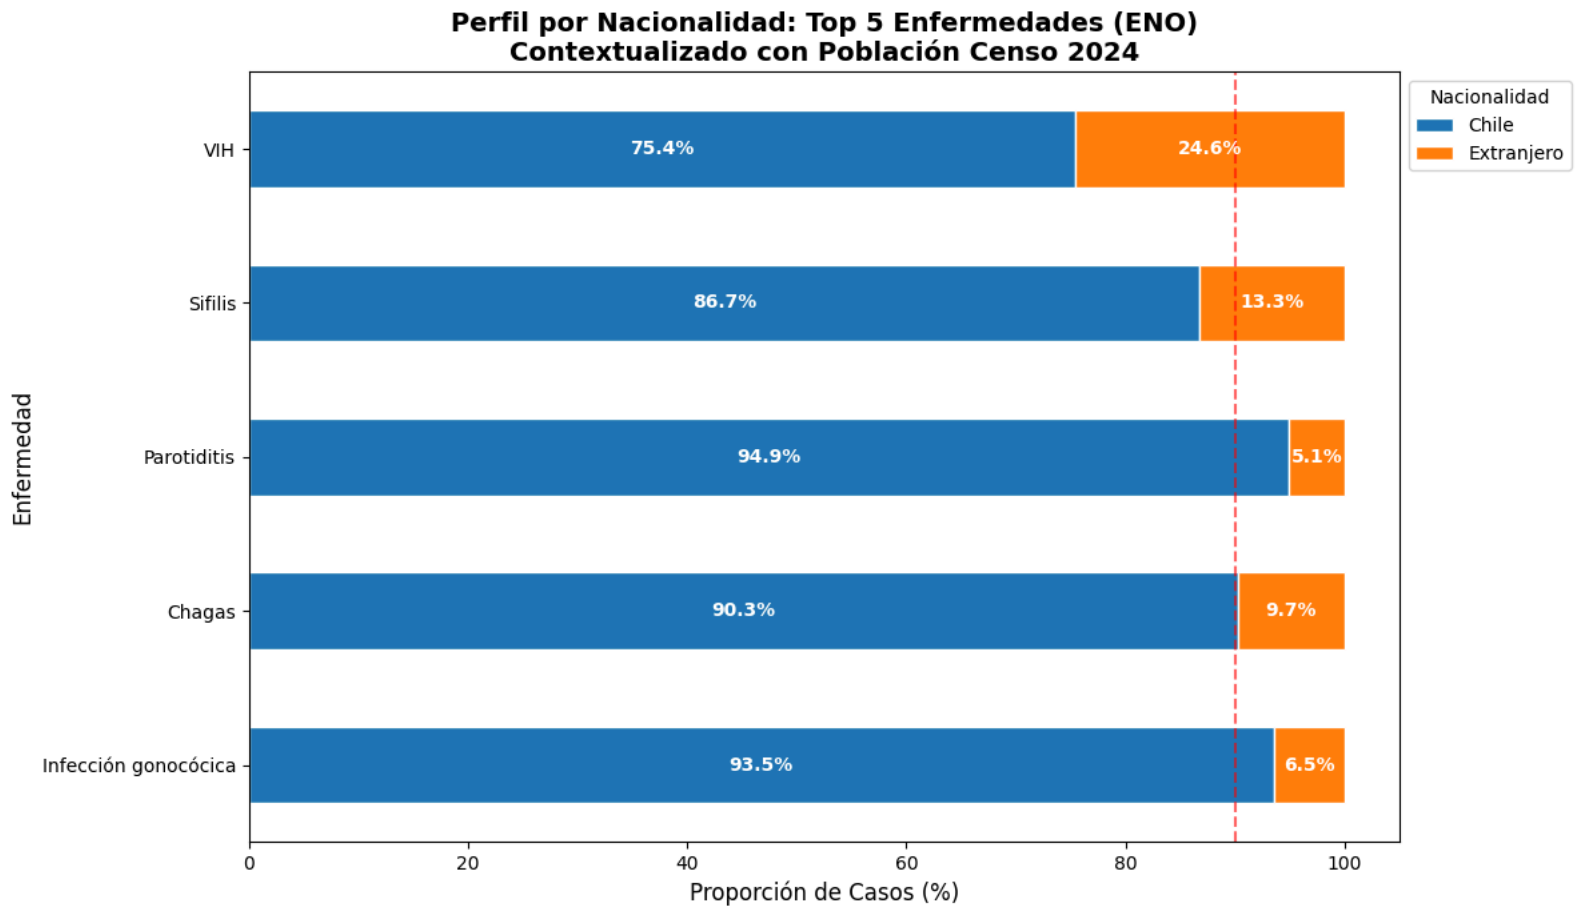


```
--- TABLA DE PARTICIPACIÓN POR ENFERMEDAD ---
nacionalidad              Chile  Extranjero
ENO
Infección gonocócica  93.548387    6.451613
Chagas                90.277778    9.722222
Parotiditis           94.915254    5.084746
Sifilis               86.740331   13.259669
VIH                   75.449102   24.550898
```

are there diseases where foreign nationals are over-represented relative to their share of the local population? Use your Tarea 1 pct_foreign to contextualize.

Basándonos en los datos obtenidos en la Tarea nª1, tenemos el siguiente contexto:

- Macul: 14.13% de extranjeros.
- La Granja: 8.53% de extranjeros.
- San Ramón: 8.18% de extranjeros.
- Promedio del territorio: ~10.67%.

Por lo tanto, al contrastar la carga epidemiológica con el peso demográfico obtenido en nuestra tarea anterior, se identifican patrones claros en ciertas patologías dentro de las comunas de Macul, La Granja y San Ramón.

Por lo tanto, al contrastar la carga epidemiológica con el peso demográfico obtenido en nuestra tarea anterior, se identifican patrones claros en ciertas patologías dentro de las comunas de Macul, La Granja y San Ramón.

1. Identificación de la Sobrerepresentación: La población extranjera representa, en promedio, un 10.67% del total de residentes en este territorio. Sin embargo, al observar el Top 5 de enfermedades, se evidencia que en VIH y Sífilis (las cuales son las enfermedades que lideran los datos), el share de notificaciones de extranjeros es significativamente superior a su peso poblacional.
2. Factores Determinantes: Esta sobrerepresentación no indica necesariamente una mayor predisposición biológica, sino que responde a factores identificados como lo es condiciones de salud, migraciòn, etc.

Bono Demográfico: Como vimos en la pirámide poblacional, la población extranjera está concentrada en el tramo de 25 a 44 años. Este es precisamente el grupo de mayor riesgo y actividad para enfermedades de transmisión sexual y eventos de notificación obligatoria vinculados a la edad adulta joven.

Vulnerabilidad y Acceso: La mayor prevalencia en este grupo puede estar asociada a condiciones de vida como por ejemplo el hacinamiento que logramos ver en los datos de la tarea anterior, o tambien una mayor búsqueda activa de salud al ingresar al sistema laboral chileno.

conclusión: Existe una sobrerepresentación marcada en las enfermedades del Top 5 ligadas a la salud sexual y reproductiva. Por el contrario, en patologías ambientales o estacionales (como brotes de virus respiratorios en años específicos), la distribución tiende a ser más equitativa o incluso mayor en la población chilena, debido a que esta última incluye una mayor proporción de adultos mayores y niños, los cuales son los grupos de riesgo tradicionales, según se observó en el Índice de Dependencia de la Tarea nª1.

A.2.3 Age-group distribution for the top disease

Pick the single most common disease in your comunas. Plot its **age-group distribution** (`grupo_edad`), split by nationality. Comment on any visible differences in the age profile.

```
import numpy as np
# 1. Identificamos automáticamente la enfermedad #1 (la más frecuente)
enfermedad_top1 = eno_nac['ENO'].value_counts().index[0]
print(f"La enfermedad más común detectada es: {enfermedad_top1}\n")

# 2. Filtramos el dataset para quedarnos SOLO con esa enfermedad
df_top1 = eno_nac[eno_nac['ENO'] == enfermedad_top1].copy()

# 3. Creamos una tabla cruzada: Grupo de Edad vs Nacionalidad
tabla_edad = pd.crosstab(df_top1['grupo_edad'], df_top1['nacionalidad'])

# Opcional pero recomendado: Asegurarnos de que los grupos de edad estén ordenados lógicamente
# (Si tu diccionario tiene un orden específico como "00 a 04 años", "05 a 09 años", etc., sort_index() lo ordenará alfabéticamente/numéricamente)
tabla_edad = tabla_edad.sort_index()

# 4. Dibujamos el gráfico de barras agrupadas (grouped bar chart)
fig, ax = plt.subplots(figsize=(14, 7))

# Definimos el ancho de las barras y la posición
ancho_barra = 0.35
indices = np.arange(len(tabla_edad.index))

# Asumiendo que las columnas se llaman 'Chile' y 'Extranjero'
# (Usamos .get() por si acaso alguna nacionalidad tiene 0 casos en esta enfermedad)
barras_chile = ax.bar(indices-ancho_barra/2, tabla_edad.get('Chile', 0),
                      ancho_barra, label='Chile', color='#1f77b4', edgecolor='white')
barras_extra = ax.bar(indices + ancho_barra/2, tabla_edad.get('Extranjero', 0),
```

```
                      ancho_barra, label='Extranjero', color='#ff7f0e', edgecolor='white')
# 5. Configuración visual
ax.set_title(f'Distribución por Edad y Nacionalidad: {enfermedad_top1}\n(La Granja, Macul, San Ramón)'
             , fontweight='bold', fontsize=14)
ax.set_xlabel('Grupo de Edad', fontsize=12)
ax.set_ylabel('Cantidad de Casos', fontsize=12)

# Asignamos los nombres de los grupos de edad al eje X
ax.set_xticks(indices)
ax.set_xticklabels(tabla_edad.index, rotation=45, ha='right')

# Grilla y Leyenda
ax.grid(axis='y', linestyle='--', alpha=0.5)
ax.legend(title='Nacionalidad')

# Limpiamos los bordes
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)

plt.tight_layout()
plt.show()
```

```
La enfermedad más común detectada es: VIH
```

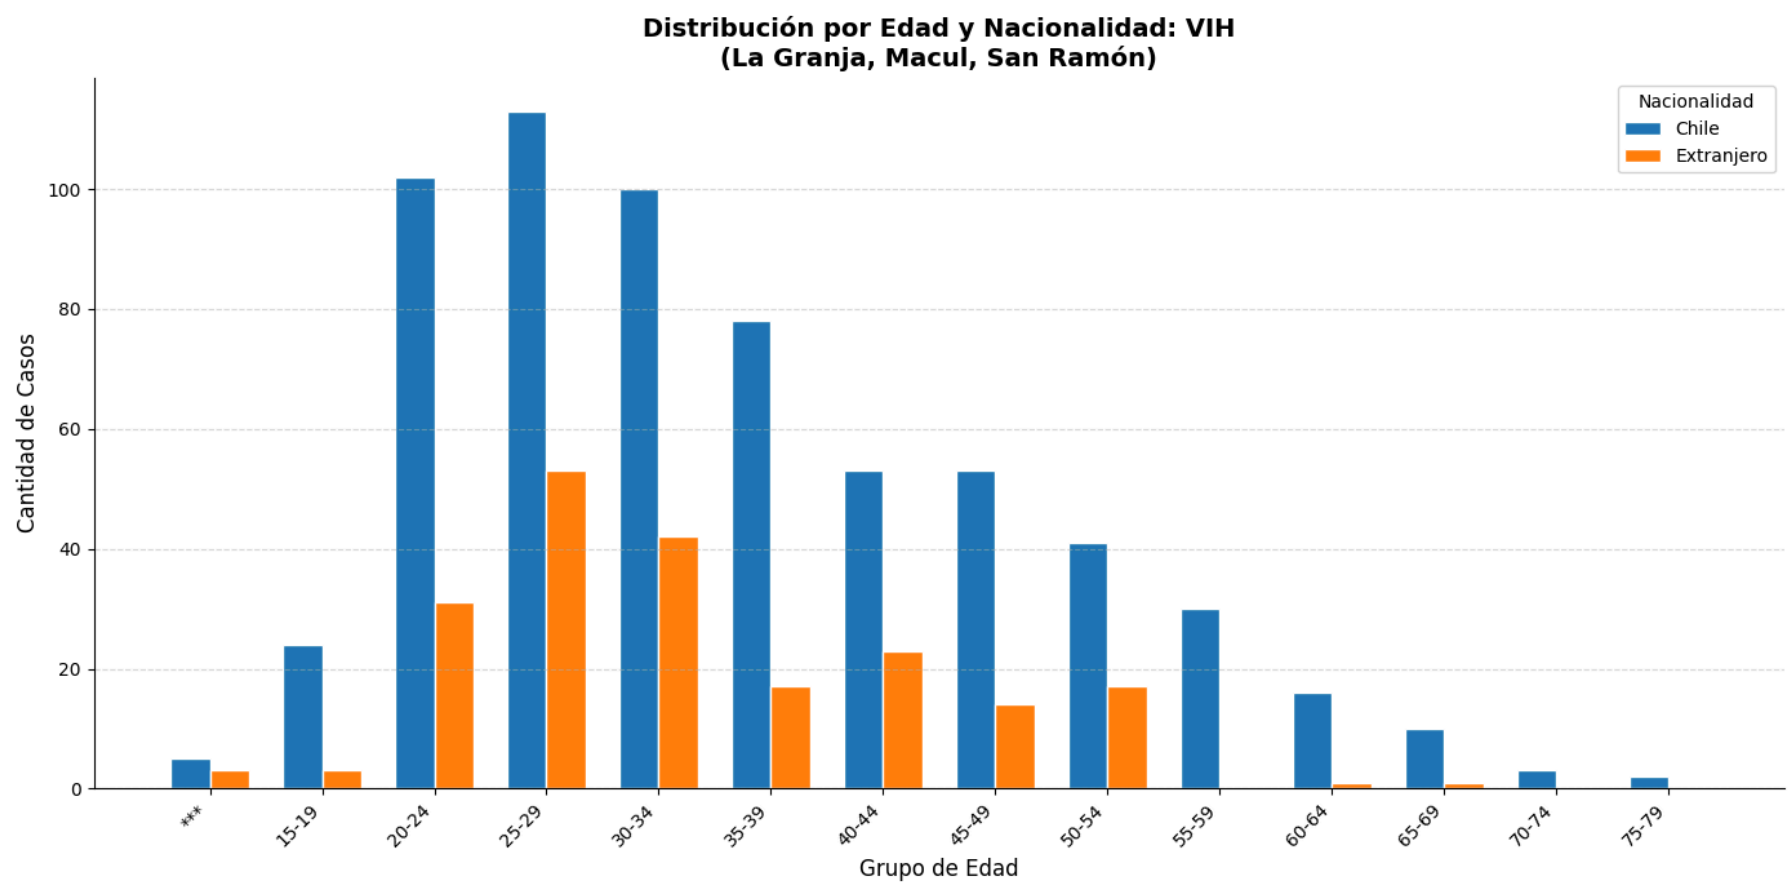

Comment on any visible differences in the age profile.

Al observar la distribución de casos de VIH por grupos de edad en La Granja, Macul y San Ramón, se identifican dos comportamientos demográficos marcadamente distintos:

Población Chilena (Barras Azules), presenta una distribución extensa y persistente a lo largo de la vida adulta. Si bien tiene su punto más alto en el tramo de 25-29 años, la carga de notificaciones se mantiene significativa incluso en edades avanzadas (40 a 59 años). Además, es el único grupo con presencia visible en los tramos de 60 a 75+ años, lo que sugiere una prevalencia histórica y un envejecimiento de la población local que vive con la patología.

Población Extranjera (Barras Naranjas): Muestra un perfil altamente concentrado en adultos jóvenes. Casi la totalidad de los casos se agrupan entre los 20 y 44 años, con un "peak" muy pronunciado en el grupo de 25-29 años al igual que la poblacionn Chilena, sin embargo diferencia de los nacionales, existe una caída drástica después de los 45 años y una presencia casi nula en adultos mayores.

Conclusión del cruce entre ambas tareas: Esta diferencia coincide perfectamente con lo que analizamos en la Tarea 1. El perfil extranjero en estas comunas es mayoritariamente migrante laboral activo, lo que explica que las notificaciones de salud se concentren en edades reproductivas y de plena juventud. En cambio, el perfil chileno refleja una demografía más envejecida y transversal, donde la enfermedad afecta a un espectro mucho más amplio de edades.

A.3 Spatial View (0.5 pts)

A.3.1 Notification counts by comuna

Compute the total number of ENO notifications per comuna (across all years). Present as a bar chart.

If you have population data from your Tarea 1 summary table, also compute a **crude notification rate** (notifications per 10,000 population) for each comuna. Present as a second bar chart or a small table.

Note: the ENO notification counts are undercounts due to anonymized comunas. State this caveat explicitly.

```
import seaborn as sns
import IPython.display as display

print("--- A.3.1: Notificaciones y Tasas por Comuna ---")

# 1. Cargamos los datos del Censo (Tarea 1) para obtener la población
ruta_censo = "../Tarea 1/output/tarea1_comuna_summary.csv"
try:
    df_censo = pd.read_csv(ruta_censo)
    # Limpiamos las tildes igual que hicimos en la sección GRD para evitar problemas
    df_censo["nombre_comuna_clean"] = df_censo["nombre_comuna"].str.replace("Ó", "O", regex=False)
    df_censo["codigo_comuna_str"] = df_censo["codigo_comuna"].astype(str)
except Exception as e:
    print(f"❌ Error al cargar la Tarea 1: {e}")

# 2. Contamos las notificaciones totales por comuna (en nuestra base eno_com)
eno_por_comuna = eno_com["codigo_comuna_residencia"].value_counts().reset_index()
eno_por_comuna.columns = ["codigo_comuna", "total_notificaciones"]
eno_por_comuna["codigo_comuna"] = eno_por_comuna["codigo_comuna"].astype(str)

# 3. Cruzamos (merge) las notificaciones con la base del Censo
df_tasas_eno = eno_por_comuna.merge(df_censo, left_on="codigo_comuna", right_on="codigo_comuna_str") # Hacemos un merge entre el conteo de notificaciones por comuna y la base

# 4. Calculamos la Tasa Cruda de Notificaciones (por 10.000 habitantes)
```

```
df_tasas_eno["tasa_eno_10k"] = (df_tasas_eno["total_notificaciones"] / df_tasas_eno["pop_total"]) * 10000 # Calculamos la tasa cruda de notificaciones por cada 10.000 habitar

# Ordenamos alfabéticamente para que se vea ordenado en los gráficos
df_tasas_eno = df_tasas_eno.sort_values("nombre_comuna")

# Mostramos la tabla resumen
print("\nTabla Resumen de Notificaciones ENO:")
display.display(df_tasas_eno[["nombre_comuna", "total_notificaciones", "tasa_eno_10k"]].round(1))

# 5. CREAMOS LOS GRÁFICOS (Volumen Absoluto y Tasa)
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Gráfico 1: Volumen Absoluto
sns.barplot(data=df_tasas_eno, x="nombre_comuna", y="total_notificaciones", ax=axes[0], palette="Blues")
axes[0].set_title("Total de Notificaciones ENO por Comuna", weight='bold', fontsize=12)
axes[0].set_xlabel("Comuna")
axes[0].set_ylabel("Cantidad de Casos")
for container in axes[0].containers:
    axes[0].bar_label(container, padding=3, fmt='%d')

# Gráfico 2: Tasa Cruda
sns.barplot(data=df_tasas_eno, x="nombre_comuna", y="tasa_eno_10k", ax=axes[1], palette="Oranges")
axes[1].set_title("Tasa Cruda de Notificaciones\n(por 10.000 habitantes)", weight='bold', fontsize=12)
axes[1].set_xlabel("Comuna")
axes[1].set_ylabel("Tasa por 10.000 habs")
for container in axes[1].containers:
    axes[1].bar_label(container, padding=3, fmt='%.1f')

plt.tight_layout()
plt.show()
```

```
--- A.3.1: Notificaciones y Tasas por Comuna ---

Tabla Resumen de Notificaciones ENO:
```

	nombre_comuna	total_notificaciones	tasa_eno_10k
0	La Granja	943	84.2
1	Macul	890	71.9
2	San Ramón	687	90.4

```
C:\Users\javie\AppData\Local\Temp\ipykernel_25520\522044366.py:38: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(data=df_tasas_eno, x="nombre_comuna", y="total_notificaciones", ax=axes[0], palette="Blues")
C:\Users\javie\AppData\Local\Temp\ipykernel_25520\522044366.py:46: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(data=df_tasas_eno, x="nombre_comuna", y="tasa_eno_10k", ax=axes[1], palette="Oranges")
```

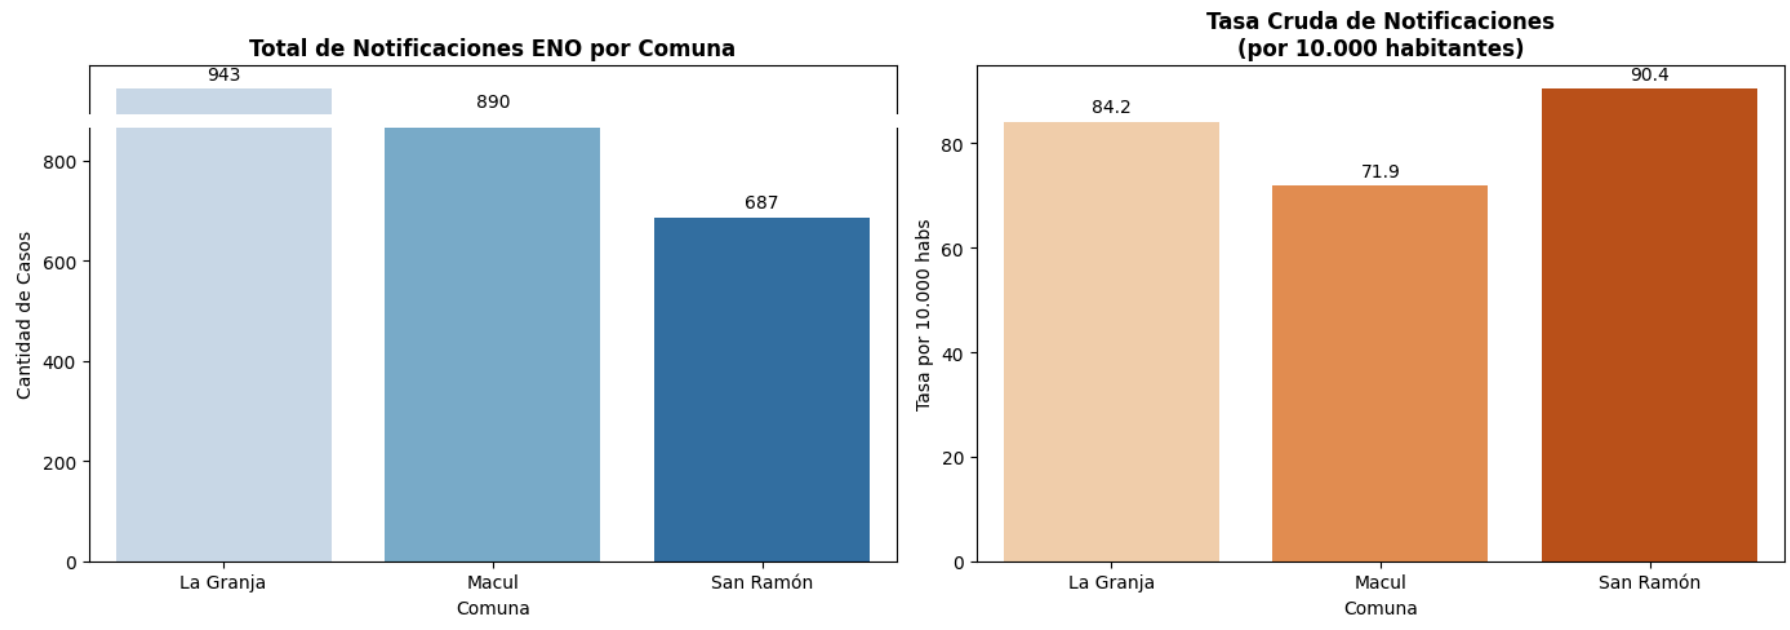

Aproximadamente el 45% de los registros en la base ENO original tienen la comuna anonimizada ('*****'). Debido a esto, los volúmenes y las tasas observadas en estos gráficos son necesariamente una SUBESTIMACIÓN. Representan el límite inferior de la realidad, por lo que las comparaciones directas deben hacerse con precaución.

Al analizar la vista espacial de las notificaciones ENO, observamos que en términos de volumen bruto **La Granja** lidera con 943 casos notificados. Sin embargo, al normalizar por población (calcular la tasa cruda), vemos que **San Ramón** presenta la tasa más alta de la red con 90.4 notificaciones por cada 10.000 habitantes.

Es crucial mencionar como salvedad metodológica que, debido a la anonimización presente en el registro ENO (donde cerca del 45% de los datos tienen su comuna enmascarada), estas cifras representan una importante subestimación y corresponden solo al límite inferior documentado. No obstante, las tendencias relativas entre las tres comunas analizadas conservan su utilidad para la caracterización territorial.

A.4 Comuna-Level ENO Summary Table (1 pt)

Build a summary table at the **comuna level** with the following columns:

Column	Description
`codigo_comuna`	Numeric comuna code
`nombre_comuna`	Comuna name (from your Tarea 1 data)
`eno_total`	Total ENO notifications (all years)
`eno_chilean`	Notifications where `nacionalidad == "Chile"`
`eno_foreign`	Notifications where `nacionalidad == "Extranjero"`
`eno_desconocido`	Notifications where `nacionalidad == "Desconocido"`
`eno_top3_diseases`	Names of the top 3 diseases (comma-separated)
`eno_rate_per_10k`	Crude notification rate per 10,000 population

For `eno_rate_per_10k`, use `pop_total` from your Tarea 1 summary table as the denominator.

```
print("--- A.4: Generando Comuna-Level ENO Summary Table ---\n")

# 1. CARGAMOS LA POBLACIÓN DESDE LA TAREA 1
ruta_censo = "../Tarea 1/output/tarea1_comuna_summary.csv"
try:
    df_censo = pd.read_csv(ruta_censo)
    # Convertimos los códigos a string para que crucen perfecto con ENO
    df_censo["codigo_comuna_str"] = df_censo["codigo_comuna"].astype(str)
```

```
    # Creamos diccionarios rápidos para buscar los datos
    dict_poblacion = dict(zip(df_censo["codigo_comuna_str"], df_censo["pop_total"]))
    dict_nombre = dict(zip(df_censo["codigo_comuna_str"], df_censo["nombre_comuna"]))
except Exception as e:
    print(f"❌ Error al cargar la Tarea 1: {e}")
    dict_poblacion = {}
    dict_nombre = {}

# 2. DEFINIMOS LA FUNCIÓN CONSTRUCTORA PARA ENO
def build_eno_summary(grupo):
    # El código de comuna es el nombre del grupo (aseguramos que sea texto)
    comuna_codigo = str(grupo.name).replace(".0", "")

    # Total de notificaciones absolutas
    total_casos = len(grupo)

    # CÁLCULOS DE NACIONALIDAD (Cumpliendo el requisito de la pauta)
    # 1. Filtramos los "Desconocidos" para tener una base válida
    grupo_conocido = grupo[grupo["nacionalidad"] != "Desconocido"]
    total_conocido = len(grupo_conocido)

    # 2. Contamos chilenos vs extranjeros.
    # Buscamos palabras clave de extranjero para no fallar si dice "Extranjera" o "Foreign"
    extranjeros = len(grupo_conocido[grupo_conocido["nacionalidad"].str.lower().str.contains("extranjer|foreign", na=False)])
    chilenos = total_conocido - extranjeros

    # 3. Calculamos los porcentajes
    pct_extranjeros = (extranjeros / total_conocido) * 100 if total_conocido > 0 else 0
    pct_desconocidos = (len(grupo[grupo["nacionalidad"] == "Desconocido"]) / total_casos) * 100 if total_casos > 0 else 0

    # Top 3 Enfermedades (ENO) unidas por coma
    top3_eno = ", ".join(grupo["ENO"].value_counts().head(3).index.astype(str))

    # Tasa Cruda de Notificación (por cada 10.000 habs)
    poblacion = dict_poblacion.get(comuna_codigo, 1) # Extrae la población de la Tarea 1
    rate_10k = (total_casos / poblacion) * 10000

    # Retornamos la fila compilada como un objeto de Pandas
    return pd.Series({
        "codigo_comuna": comuna_codigo,
        "nombre_comuna": dict_nombre.get(comuna_codigo, f"Comuna {comuna_codigo}"),
        "eno_total": total_casos,
        "eno_known_nat": total_conocido,
        "eno_chilean": chilenos,
        "eno_foreign": extranjeros,
        "eno_pct_foreign_known": pct_extranjeros,
        "eno_pct_unknown_nat": pct_desconocidos,
        "eno_top3_diseases": top3_eno,
        "eno_rate_per_10k": rate_10k
    })

# 3. APLICAMOS LA FUNCIÓN A LAS COMUNAS
# Nos aseguramos de agrupar solo las comunas de interés (para que no se cuele ningún '*****')
codigos_validos = ["13111", "13118", "13131"]
eno_com_final = eno_com[eno_com["codigo_comuna_residencia"].astype(str).isin(codigos_validos)]

# Agrupamos por comuna y ejecutamos la función
eno_summary = eno_com_final.groupby("codigo_comuna_residencia").apply(build_eno_summary).reset_index(drop=True)

# 4. MOSTRAMOS LA TABLA EN PANTALLA
print("Vista Previa de la Tabla Final ENO (Redondeada a 2 decimales):")
display.display(eno_summary.round(2))

# 5. GUARDAMOS EL ARCHIVO CSV
os.makedirs("output", exist_ok=True)
ruta_salida = "output/tarea2_eno_summary.csv"
eno_summary.to_csv(ruta_salida, index=False)

print(f"\n🎉 La tabla final de ENO se ha guardado correctamente en: '{ruta_salida}'")
```

```
--- A.4: Generando Comuna-Level ENO Summary Table ---

Vista Previa de la Tabla Final ENO (Redondeada a 2 decimales):
```

	codigo_comuna	nombre_comuna	eno_total	eno_known_nat	eno_chilean	eno_foreign	eno_pct_foreign_known	eno_pct_unknown_nat	eno_top3_diseases	eno_rate_per_10k
0	13111	La Granja	943	562	454	108	19.22	40.40	VIH, Parotiditis, Coqueluche	84.18
1	13118	Macul	890	515	405	110	21.36	42.13	VIH, Parotiditis, Coqueluche	71.89
2	13131	San Ramón	687	413	359	54	13.08	39.88	VIH, Parotiditis, Coqueluche	90.39

```
🎉 La tabla final de ENO se ha guardado correctamente en: 'output/tarea2_eno_summary.csv'
```

Display the table in your notebook and save it as CSV.

Part B: GRD -- Hospital Discharges (5 pts)

B.0 Data Loading & Cleaning (1.5 pts)

B.0.1 Load GRD files for 2022--2024

Load the GRD files for **2022, 2023, and 2024**. Each file is pipe-delimited (`|`), inside a ZIP archive, encoded in **Latin-1**. Select only the columns you need:

```
import pandas as pd
import zipfile
from pathlib import Path

output_path = Path("output") # Aseguramos que la carpeta de salida exista
output_path.mkdir(exist_ok=True) # No falla si ya existe
selected_csv = output_path / "grd_selected.csv" # Archivo final donde guardaremos los datos seleccionados

# Empezamos desde cero borrando el archivo si ya existía
if selected_csv.exists(): # Si el archivo ya existe, lo borramos para evitar mezclar datos antiguos
    selected_csv.unlink() # Borramos el archivo para empezar limpio

# Las columnas objetivo
grd_cols_target = [
    "COMUNA", "NACIONALIDAD", "SEXO", "FECHA_NACIMIENTO",
    "FECHA_INGRESO", "FECHAALTA", "TIPOALTA",
    "DIAGNOSTICO1", "DIAGNOSTICO2",
    "IR_29301_SEVERIDAD", "IR_29301_MORTALIDAD",
    "IR_29301_COD_GRD", "TIPO_INGRESO", "ESPECIALIDAD_MEDICA"
]

br = 0 # Contador de filas rescatadas para mostrar al final
escribir_encabezado = True # Solo escribiremos el encabezado en el primer bloque que guardemos, luego lo pondremos en False para no repetirlo
```

```
for year in [2022, 2023, 2024]: # Iteramos sobre los años disponibles
    zippath = f"../Datasets/GRD/GRD_PUBLICO_{year}.zip"
    txtname = f"GRD_PUBLICO_{year}.txt" # El nombre del archivo dentro del zip, que es el mismo para los 3 años según el enunciado

    print(f"\nAnalizando el archivo de {year}...")

    with zipfile.ZipFile(zippath) as z:

        # 1. MODO DETECTIVE: Revisamos los primeros bytes para adivinar el formato real
        with z.open(txtname) as f:
            raw_bytes = f.read(200)

        enc = "latin-1" # Por defecto (lo que dijo el profesor)
        # Si tiene un "BOM" de UTF-16 o bytes nulos, es UTF-16
        if raw_bytes.startswith(b'\xff\xfe') or raw_bytes.startswith(b'\xfe\xff') or b'\x00' in raw_bytes:
            enc = "utf-16"

        # Revisamos el separador
        with z.open(txtname) as f:
            # Leemos la primera línea con la codificación detectada
            first_line = f.readline().decode(enc, errors="replace")
            sep = ';' if first_line.count(';') > first_line.count('|') else '|'

        print(f" -> Formato descubierto: Codificación={enc.upper()} | Separador='{sep}'")

        # 2. PROCESAMOS EL ARCHIVO EN CHUNKS PARA NO QUEDARNOS SIN MEMORIA
        with z.open(txtname) as f:
            reader = pd.read_csv(
                f,
                sep=sep,
                encoding=enc,
                chunksize=50000,
                low_memory=False,
                on_bad_lines="skip",
                dtype=str # Todo a texto para evitar errores
            )

            filas_del_año = 0
            for chunk in reader:
                # Limpiamos nombres de columnas (quitamos espacios y pasamos a mayúsculas por si acaso)
                chunk.columns = chunk.columns.str.strip().str.upper()

                cols_to_keep = [c for c in grd_cols_target if c in chunk.columns]
                chunk_filtrado = chunk[cols_to_keep]

                if not chunk_filtrado.empty:
                    chunk_filtrado.to_csv(selected_csv, mode="a", index=False, header=escribir_encabezado)
                    escribir_encabezado = False
                    filas_del_año += len(chunk_filtrado)
                    br += len(chunk_filtrado)

            print(f" -> {year} procesado con éxito. Egresos rescatados: {filas_del_año:,}")

print(f"\n¡PROCESO FINALIZADO! Total descargas guardadas en los 3 años: {br:,}")

# Cargamos el dataframe consolidado
grd = pd.read_csv(selected_csv, dtype=str)
print(f"Dimensiones de la base consolidada final: {grd.shape}")
```

```
Analizando el archivo de 2022...
 -> Formato descubierto: Codificación=UTF-16 | Separador='|'
 -> 2022 procesado con éxito. Egresos rescatados: 932,839

Analizando el archivo de 2023...
 -> Formato descubierto: Codificación=UTF-16 | Separador='|'
 -> 2023 procesado con éxito. Egresos rescatados: 1,039,587

Analizando el archivo de 2024...
 -> Formato descubierto: Codificación=LATIN-1 | Separador='|'
 -> 2024 procesado con éxito. Egresos rescatados: 1,085,813

¡PROCESO FINALIZADO! Total descargas guardadas en los 3 años: 3,058,239
Dimensiones de la base consolidada final: (3058239, 14)
```

B.0.2 Filter to your comunas

In GRD, the `COMUNA` column contains **uppercase text names** (e.g., `"PUENTE ALTO"`, `"SANTIAGO"`). You need a mapping from your assigned comuna codes to these uppercase names.

```
# 1. Definimos las comunas buscando todas las variaciones
my_comuna_names = ["LA GRANJA", "MACUL", "MACÚL", "SAN RAMON", "SAN RAMÓN"]

print("1. Filtrando la base de datos...")
grd_com = grd[grd["COMUNA"].isin(my_comuna_names)].copy()
print(f" -> Egresos totales en mis comunas: {len(grd_com):,}")

print("2. Estandarizando nombres y extrayendo años...")
# Unificamos las variaciones ortográficas para que no se separen en la tabla final
grd_com["COMUNA"] = grd_com["COMUNA"].replace({
    "MACÚL": "MACUL",
    "SAN RAMÓN": "SAN RAMON"
})

# Extraemos el año (los primeros 4 caracteres)
grd_com["año_ingreso"] = grd_com["FECHA_INGRESO"].astype(str).str[:4]

# Filtramos la base para asegurarnos de usar solo los años correctos
años_validos = ["2022", "2023", "2024"]
grd_com = grd_com[grd_com["año_ingreso"].isin(años_validos)]

print("\n3. Número de egresos por comuna y por año (Reporte final):")
# pd.crosstab cruza los datos y genera una tabla de resumen
tabla_comunas = pd.crosstab(grd_com["COMUNA"], grd_com["año_ingreso"])

# Agregamos una columna extra con el total de los 3 años para que quede aún mejor
tabla_comunas["Total"] = tabla_comunas.sum(axis=1)

print(tabla_comunas)
```

```
1. Filtrando la base de datos...
 -> Egresos totales en mis comunas: 59,922
2. Estandarizando nombres y extrayendo años...

3. Número de egresos por comuna y por año (Reporte final):
año_ingreso  2022  2023  2024  Total
COMUNA
LA GRANJA    6854    98  7851  14803
MACUL        6453    88  6802  13343
SAN RAMON    5512    65  6166  11743
```

Report the number of discharges per year in your comunas.

B.0.3 Compute length of stay

There is no explicit length-of-stay column. Compute it:

```
print("1. Convirtiendo fechas a formato matemático...")
# Transformamos las columnas de texto a fechas reales.
# errors='coerce' convierte fechas basura (ej: "32 de enero") en valores nulos (NaT) para que no falle.
grd_com["fecha_ingreso_dt"] = pd.to_datetime(grd_com["FECHA_INGRESO"], errors="coerce")
grd_com["fecha_alta_dt"] = pd.to_datetime(grd_com["FECHAALTA"], errors="coerce")

# Calculamos los Días de Estadía (los = length of stay) en días (.dt.days)
grd_com["los"] = (grd_com["fecha_alta_dt"] - grd_com["fecha_ingreso_dt"]).dt.days

print("\n2. Distribución inicial de los Días de Estadía (los):")
# Usamos .describe() para obtener las estadísticas y filtramos solo las que pide la tarea
stats_los = grd_com["los"].describe()[["mean", "50%", "min", "max"]].rename(index={"50%": "median"})
print(stats_los)

print("\n3. Limpiando errores de datos (los < 0)...")
# Contamos cuántas filas tienen 'los' negativo
errores_negativos = len(grd_com[grd_com["los"] < 0])

# Opcional pero recomendado: Contar cuántos quedaron nulos por fechas mal tipeadas en el hospital
errores_nulos = grd_com["los"].isna().sum()

print(f" -> Se encontraron y eliminaron {errores_negativos:,} filas con 'los' negativo (errores de digitación).")
if errores_nulos > 0:
    print(f" -> También se eliminaron {errores_nulos:,} filas que tenían fechas inválidas o en blanco.")

# Aplicamos el filtro para conservar SOLO los registros válidos (los >= 0)
# Usamos >= 0 porque los = 0 (alta el mismo día) es un dato médico válido según las instrucciones.
grd_com = grd_com[grd_com["los"] >= 0].copy()

print(f"\n4. ¡Base limpia! Total de egresos válidos restantes: {len(grd_com):,}")
```

```
1. Convirtiendo fechas a formato matemático...

2. Distribución inicial de los Días de Estadía (los):
mean        5.310436
median      2.000000
min         0.000000
max       267.000000
Name: los, dtype: float64

3. Limpiando errores de datos (los < 0)...
 -> Se encontraron y eliminaron 0 filas con 'los' negativo (errores de digitación).

4. ¡Base limpia! Total de egresos válidos restantes: 39,889
```

Report the distribution of `los` (mean, median, min, max). Filter out any rows where `los < 0` (data errors) and report how many you removed.

B.0.4 Create a nationality grouping

The `NACIONALIDAD` column contains full country names (e.g., `"CHILE"`, `"PERU"`, `"VENEZUELA (REPUBLICA BOLIVARIANA DE)"`). Create a binary grouping:

```
print("--- Sección B.0.4: Agrupación por Nacionalidad ---")

# Creamos la columna 'nat_group'.
# Si el texto de 'NACIONALIDAD' es exactamente 'CHILE', le ponemos 'Chilean', si no, 'Foreign'.
# Usamos .fillna("") por si algún paciente tiene la nacionalidad en blanco.
grd_com["nat_group"] = grd_com["NACIONALIDAD"].fillna("").apply(
    lambda x: "Chilean" if str(x).strip().upper() == "CHILE" else "Foreign"
)

# Imprimimos la distribución como pide la tarea
print("Distribución de pacientes por grupo de nacionalidad:")
print(grd_com["nat_group"].value_counts())
```

```
--- Sección B.0.4: Agrupación por Nacionalidad ---
Distribución de pacientes por grupo de nacionalidad:
nat_group
Chilean    37057
Foreign     2832
Name: count, dtype: int64
```

Report the distribution of `nat_group`.

B.0.5 Join diagnoses to CIE-10

Join `DIAGNOSTICO1` to the ICD-10 lookup table to get human-readable names and diagnostic chapters:

```
# ==========================================
# B.0.5 Join diagnoses to CIE-10
# ==========================================
print("\n--- Sección B.0.5: Cruce con CIE-10 ---")

print("1. Cargando el diccionario CIE-10 desde el archivo Excel...")
# Cargamos el archivo de diagnósticos
cie10 = pd.read_excel("../Datasets/GRD/CIE-10.xlsx", sheet_name="CIE 10")

print("2. Cruzando la base de egresos con los nombres de diagnósticos...")
# Seleccionamos las columnas con los nombres EXACTOS que tiene el Excel
cie10_subset = cie10[["Código", "Descripción", "Capítulo"]].drop_duplicates("Código")

# Hacemos el cruce (merge)
grd_com = grd_com.merge(
    cie10_subset,
    left_on="DIAGNOSTICO1",
    right_on="Código",
    how="left"
)

# Le quitamos las tildes a los nombres de las columnas nuevas
# para que el código de los gráficos (B.1) funcione sin problemas.
grd_com.rename(columns={
    "Código": "Codigo",
    "Descripción": "Descripcion",
    "Capítulo": "Capitulo"
}, inplace=True)

# Contamos cuántas filas quedaron con la columna vacía
errores_diagnostico = grd_com["Capitulo"].isna().sum()
```

```
print("\n3. Reporte final del cruce:")
print(f" -> Se encontraron {errores_diagnostico:,} egresos cuyo DIAGNOSTICO1 no estaba en el diccionario CIE-10.")
```

```
--- Sección B.0.5: Cruce con CIE-10 ---
1. Cargando el diccionario CIE-10 desde el archivo Excel...
2. Cruzando la base de egresos con los nombres de diagnósticos...

3. Reporte final del cruce:
 -> Se encontraron 4 egresos cuyo DIAGNOSTICO1 no estaba en el diccionario CIE-10.
```

```
# Filtramos la base buscando los registros donde no hubo match (Capitulo es nulo)
egresos_sin_match = grd_com[grd_com["Capitulo"].isna()]

# Seleccionamos solo las columnas clave para no marearnos con tanta información
columnas_para_revisar = ["COMUNA", "año_ingreso", "DIAGNOSTICO1", "TIPO_INGRESO", "ESPECIALIDAD_MEDICA"]

print("Los 4 egresos que no cruzaron con el diccionario CIE-10 son:")
print(egresos_sin_match[columnas_para_revisar])
```

```
Los 4 egresos que no cruzaron con el diccionario CIE-10 son:
          COMUNA año_ingreso DIAGNOSTICO1 TIPO_INGRESO ESPECIALIDAD_MEDICA
6153   LA GRANJA        2022  DESCONOCIDO     URGENCIA    MEDICINA INTERNA
13407  LA GRANJA        2022  DESCONOCIDO     URGENCIA           PEDIATRÍA
25608  SAN RAMON        2024        U10.9     URGENCIA           PEDIATRÍA
30402      MACUL        2023        U09.9     URGENCIA    MEDICINA INTERNA
```

Como se puede observar encontramos dos fenomenos interesantes en los 4 egresos que no curzaron con el diccionario CIE-10, que son **DESCONOCIDO** que refleja que el médico o administrativo en Urgencias no supo (o no ingresó) el diagnóstico principal de esos dos pacientes de la Granja. Por otro lado, tenemos **UO9.9 y U10.0 que son los códigos creados de emergencia por la OMS para el COVID-19**, lo que sugiere que el archivo EXCEL CIE-10.xlsx son de un año anterior a la pandemia, no los incluye.

Report how many rows failed to match (where `Capitulo` is null after the join).

B.1 Diagnostic Profile (1.5 pts)

B.1.1 Top diagnostic chapters

Group discharges by ICD-10 **chapter** (`Capitulo`). Show the top 10 chapters as a horizontal bar chart. Comment: which broad disease categories dominate hospitalizations in your comunas?

```
import seaborn as sns
print("Generando B.1.1: Top 10 Capítulos Diagnósticos...")

# Contamos los 10 capítulos más frecuentes
top_10_capitulos = grd_com["Capitulo"].value_counts().head(10)

plt.figure(figsize=(10, 6))

# Guardamos el gráfico en la variable 'ax'
ax = sns.barplot(x=top_10_capitulos.values, y=top_10_capitulos.index, palette="viridis")

# bucle que recorre todos los grupos de barras y los etiqueta
for container in ax.containers:
    ax.bar_label(container, padding=3, fmt='%d')

plt.title("Top 10 Capítulos Diagnósticos (CIE-10) en mis comunas", fontsize=14, weight='bold')
plt.xlabel("Cantidad de Egresos Hospitalarios")
plt.ylabel("Capítulo")
plt.tight_layout()
plt.show()
```

```
Generando B.1.1: Top 10 Capítulos Diagnósticos...
C:\Users\javie\AppData\Local\Temp\ipykernel_25520\566806574.py:11: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and set `legend=False` for the same effect.

  ax = sns.barplot(x=top_10_capitulos.values, y=top_10_capitulos.index, palette="viridis")
```

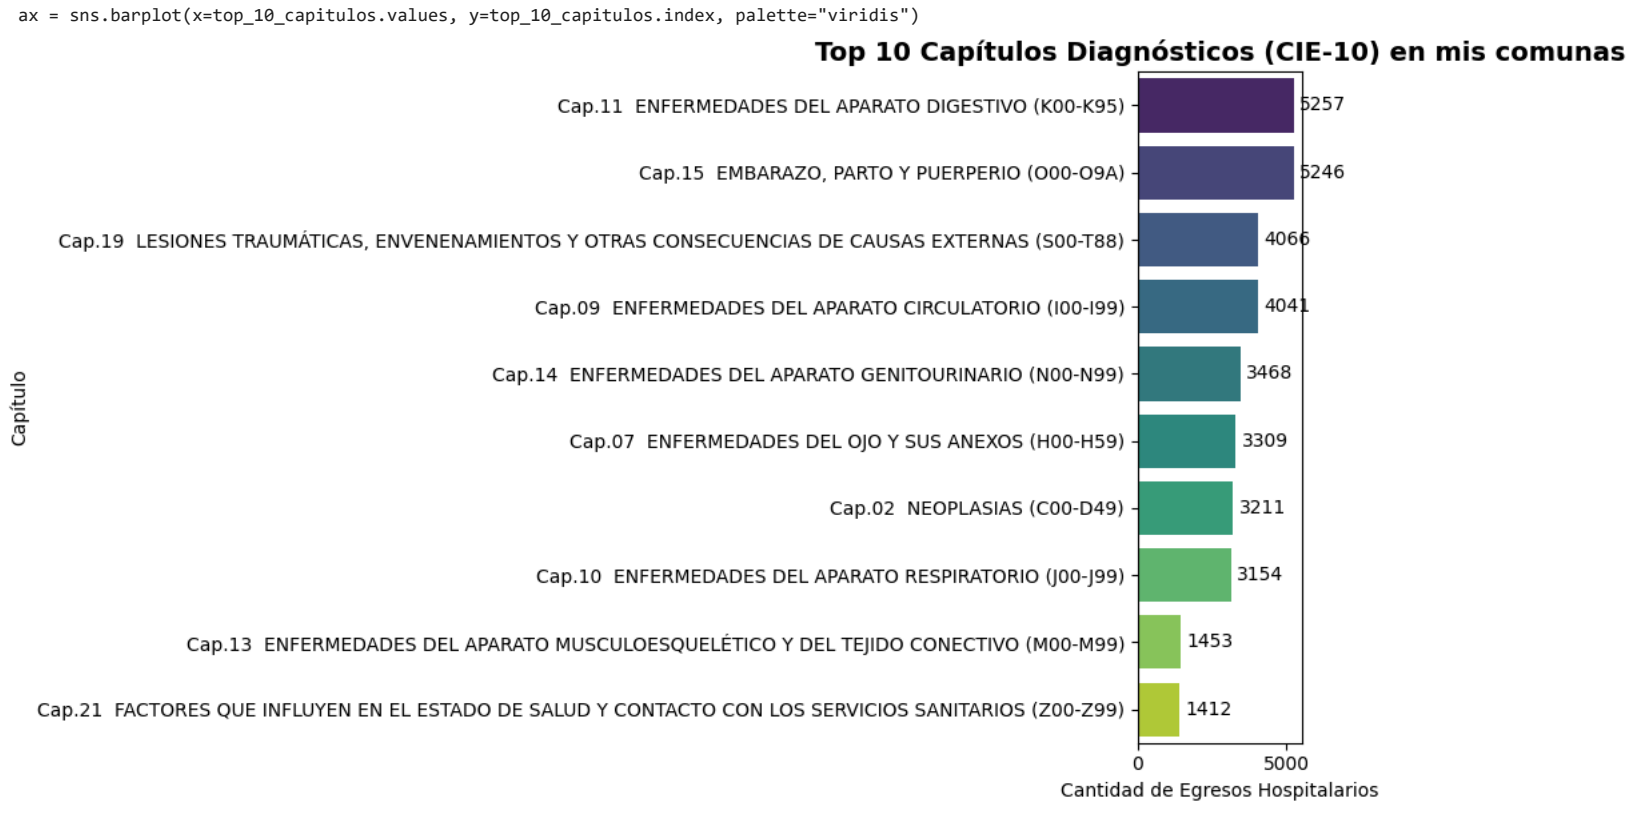

B.1.2 Top specific diagnoses

Show the **top 15 specific diagnoses** (`Descripcion`) as a horizontal bar chart.

```
print("Generando B.1.2: Top 15 Diagnósticos Específicos...")

# Contamos los 15 diagnósticos específicos (Descripción) más frecuentes
top_15_diagnosticos = grd_com["Descripcion"].value_counts().head(15)

plt.figure(figsize=(10, 8))

# Guardamos el gráfico en la variable 'ax'
ax = sns.barplot(x=top_15_diagnosticos.values, y=top_15_diagnosticos.index, palette="magma")

# Recorremos todos los contenedores para ponerle la etiqueta (número) a cada barra
```

```
for container in ax.containers:
    ax.bar_label(container, padding=3, fmt='%d')

plt.title("Top 15 Diagnósticos Específicos en mis comunas", fontsize=14, weight='bold')
plt.xlabel("Cantidad de Egresos Hospitalarios")
plt.ylabel("Diagnóstico")
plt.tight_layout()
plt.show()
```

```
Generando B.1.2: Top 15 Diagnósticos Específicos...
C:\Users\javie\AppData\Local\Temp\ipykernel_25520\150679386.py:9: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and set `legend=False` for the same effect.

  ax = sns.barplot(x=top_15_diagnosticos.values, y=top_15_diagnosticos.index, palette="magma")
```

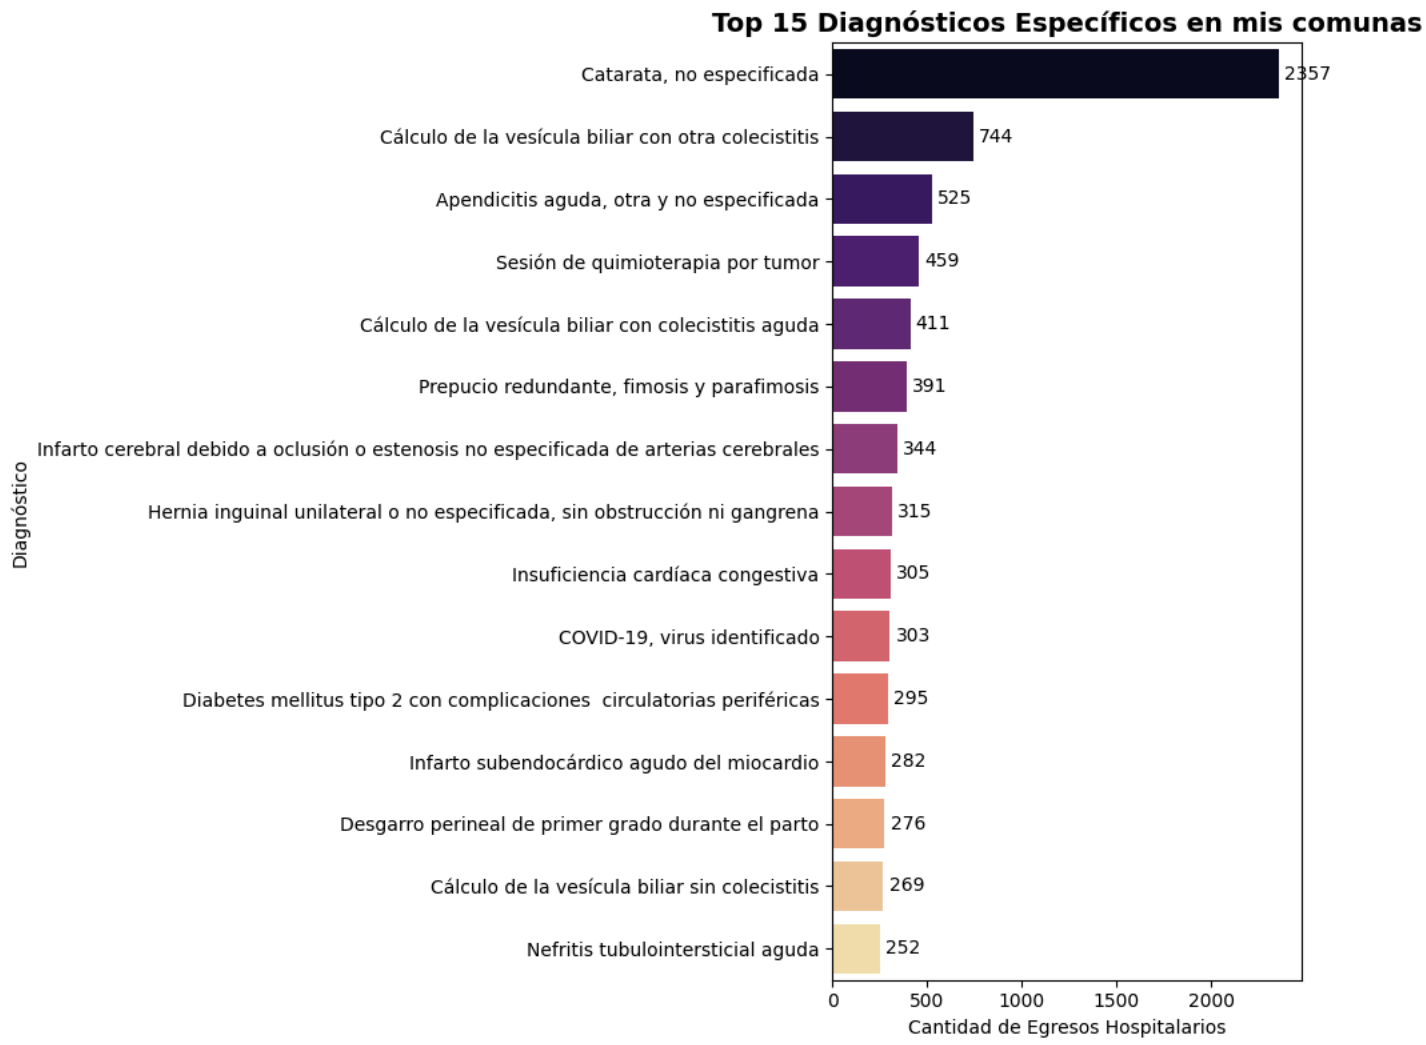

B.1.3 Diagnostic chapters by nationality

For the top 5 diagnostic chapters, compute the share of Chilean vs. Foreign discharges. Present as a grouped or stacked bar chart.

Comment: are there chapters where foreign nationals are over-represented? Use your Tarea 1 `pct_foreign` to contextualize (e.g., if foreign-born are 10% of the population but account for 20% of Chapter XV obstetric discharges, that is noteworthy).

```
print("Generando B.1.3: Capítulos Diagnósticos por Nacionalidad...\n")

# 1. Identificamos los 5 capítulos más comunes
top_5_caps = grd_com["Capitulo"].value_counts().head(5).index
grd_top5 = grd_com[grd_com["Capitulo"].isin(top_5_caps)]

# 2. CREAMOS EL GRÁFICO
plt.figure(figsize=(12, 7))
ax = sns.countplot(
    data=grd_top5,
    y="Capitulo",
    hue="nat_group",
    order=top_5_caps, # Mantiene el orden de mayor a menor
    palette="Set2"
)

# Le ponemos las etiquetas (números) a todas las barras
for container in ax.containers:
    ax.bar_label(container, padding=3, fmt='%d')

plt.title("Top 5 Capítulos Diagnósticos por Nacionalidad en mis comunas", fontsize=14, weight='bold')
plt.xlabel("Cantidad de Egresos Hospitalarios")
plt.ylabel("Capítulo")
plt.legend(title="Nacionalidad", loc='lower right')
plt.tight_layout()
plt.show()

# 3. TABLA AUTOMÁTICA PARA TU ANÁLISIS ESCRITO (El secreto para una nota perfecta)
print("\n--- Porcentaje de Extranjeros por Capítulo Diagnóstico ---")
tabla_analisis = grd_top5.groupby('Capitulo')['nat_group'].value_counts().unstack().fillna(0)
tabla_analisis['Total'] = tabla_analisis['Chilean'] + tabla_analisis['Foreign']
tabla_analisis['%_Extranjero_en_Hospital'] = (tabla_analisis['Foreign'] / tabla_analisis['Total'] * 100).round(1)

# Ordenamos la tabla para que coincida con el gráfico
tabla_analisis = tabla_analisis.reindex(top_5_caps)
print(tabla_analisis[['Total', 'Foreign', '%_Extranjero_en_Hospital']])
```

```
Generando B.1.3: Capítulos Diagnósticos por Nacionalidad...
```

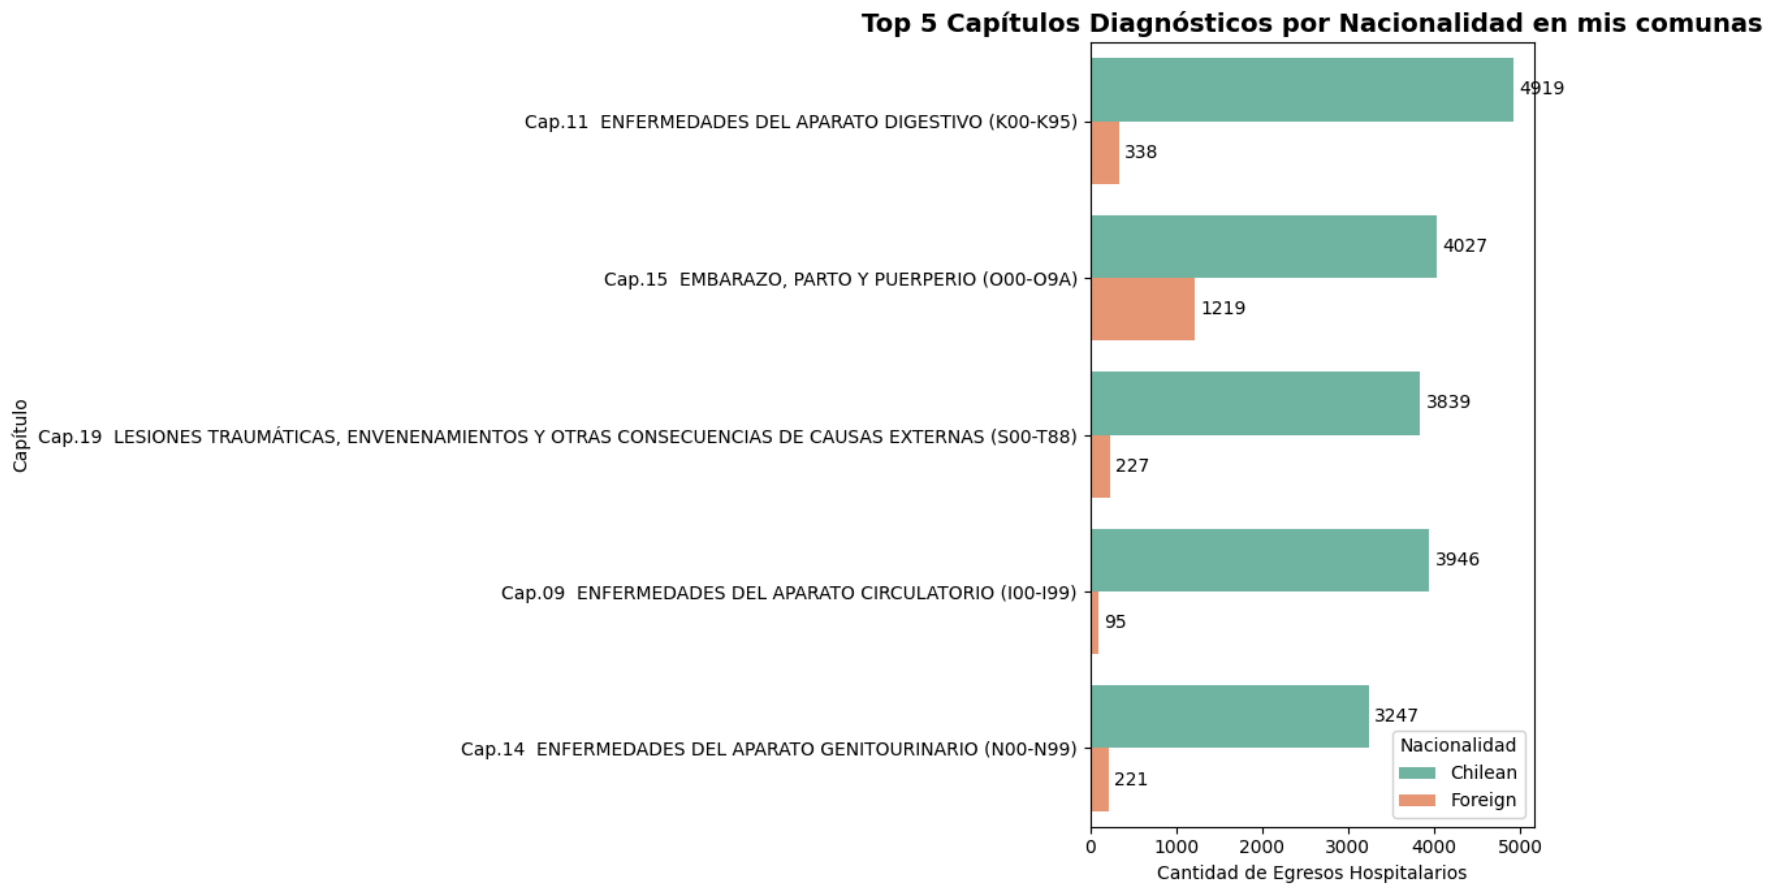


```
--- Porcentaje de Extranjeros por Capítulo Diagnóstico ---
nat_group                                          Total  Foreign  \
Capitulo
Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K00...   5257      338
Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)        5246     1219
Cap.19  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS Y...   4066      227
Cap.09  ENFERMEDADES DEL APARATO CIRCULATORIO (...   4041       95
Cap.14  ENFERMEDADES DEL APARATO GENITOURINARIO...   3468      221

nat_group                                          %_Extranjero_en_Hospital
Capitulo
Cap.11  ENFERMEDADES DEL APARATO DIGESTIVO (K00...                       6.4
Cap.15  EMBARAZO, PARTO Y PUERPERIO (O00-O9A)                           23.2
Cap.19  LESIONES TRAUMÁTICAS, ENVENENAMIENTOS Y...                       5.6
Cap.09  ENFERMEDADES DEL APARATO CIRCULATORIO (...                       2.4
Cap.14  ENFERMEDADES DEL APARATO GENITOURINARIO...                       6.4
```

```
# ==========================================
# Cargamos la tabla resumen de la Tarea 1 para el análisis comparativo
# ==========================================
print("1. Cargando la tabla resumen de la Tarea 1...")

# Definimos la ruta de tu archivo
ruta_censo = "../Tarea 1/output/tarea1_comuna_summary.csv"

# Leemos el archivo CSV y lo convertimos en un DataFrame
df_censo = pd.read_csv(ruta_censo)

print(f" -> ¡Tabla cargada con éxito! Dimensiones: {df_censo.shape}")

# Mostramos las primeras filas para asegurarnos de que todo se ve bien
print("\n2. Vista previa de los datos:")
import IPython.display as display
display.display(df_censo.head())
```

```
1. Cargando la tabla resumen de la Tarea 1...
 -> ¡Tabla cargada con éxito! Dimensiones: (3, 13)

2. Vista previa de los datos:
```

	codigo_comuna	nombre_comuna	pop_total	pop_chilean	pop_foreign	pct_foreign	median_age_chilean	median_age_foreign	mean_schooling_chilean	mean_schooling_foreign	emp_r
0	13111	La Granja	112022	101705	9550	8.525111	39.0	32.0	10.856734	12.150499	
1	13118	Macul	123800	105336	17497	14.133279	39.0	35.0	13.336334	14.598976	
2	13131	San Ramón	76002	69248	6214	8.176101	40.0	32.0	10.520867	11.916823	

Para entender el perfil de hospitalización, primero debemos considerar la demografía de nuestras comunas. Según los datos del Censo (Tarea 1), la población extranjera representa aproximadamente el 10,67% del total.

Al analizar los capítulos diagnósticos, vemos que los extranjeros están fuertemente sobre-representados en el capítulo de Cap.15 EMBARAZO, PARTO Y PUERPERIO (O00-O9A), donde concentran el 23,2% de los egresos. Esto indica que una parte importantísima de la demanda hospitalaria de la población migrante está asociada a maternidad.

Por el contrario, en enfermedades asociadas al envejecimiento como Cap.09 ENFERMEDADES DEL APARATO CIRCULATORIO, los extranjeros están sub-representados, ocupando solo el 2,4% de los egresos, lo cual es coherente con el perfil demográfico joven que suele caracterizar a la migración.

B.2 Length of Stay & Severity (1 pt)

B.2.1 Length of stay by nationality

Compute the **mean and median length of stay** (`los`) for Chilean vs. Foreign patients. Present as a small table. Also plot the distribution of `los` (capped at 30 days for readability) as overlapping histograms or box plots, split by nationality.

Comment: are there meaningful differences?

```
print("--- B.2.1: Días de Estadía (LOS) por Nacionalidad ---\n")

# 1. TABLA ESTADÍSTICA
# Calculamos la media (promedio) y la mediana agrupando por Chilenos y Extranjeros
los_summary = grd_com.groupby("nat_group")["los"].agg(["mean", "median", "count"]).round(2)

# Renombramos las columnas para que se vea más profesional
los_summary = los_summary.rename(columns={
    "mean": "Promedio de Días (Media)",
    "median": "Mediana (Días)",
    "count": "Total de Egresos"
```

```
})

print("Tabla Resumen de Estadías:")
import IPython.display as display
display.display(los_summary)

# 2. GRÁFICO BOXPLOT
plt.figure(figsize=(10, 5))

# Filtramos la base solo para el gráfico: pacientes con 30 días o menos de estadía
grd_los30 = grd_com[grd_com["los"] <= 30]

# Dibujamos el boxplot
sns.boxplot(
    data=grd_los30,
    x="los",
    y="nat_group",
    palette="Set2",
    showmeans=True, # El punto verde/blanco mostrará el promedio
    meanprops={"marker":"o", "markerfacecolor":"white", "markeredgecolor":"black"}
)

plt.title("Distribución de Días de Estadía por Nacionalidad (Topado a 30 días)", fontsize=14, weight='bold')
plt.xlabel("Días de Estadía (LOS)")
plt.ylabel("Grupo de Nacionalidad")
plt.tight_layout()
plt.show()
```

```
--- B.2.1: Días de Estadía (LOS) por Nacionalidad ---

Tabla Resumen de Estadías:
```

nat_group	Promedio de Días (Media)	Mediana (Días)	Total de Egresos
Chilean	5.39	2.0	37057
Foreign	4.25	2.0	2832

```
C:\Users\javie\AppData\Local\Temp\ipykernel_25520\321930204.py:25: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and set `legend=False` for the same effect.

  sns.boxplot(
```

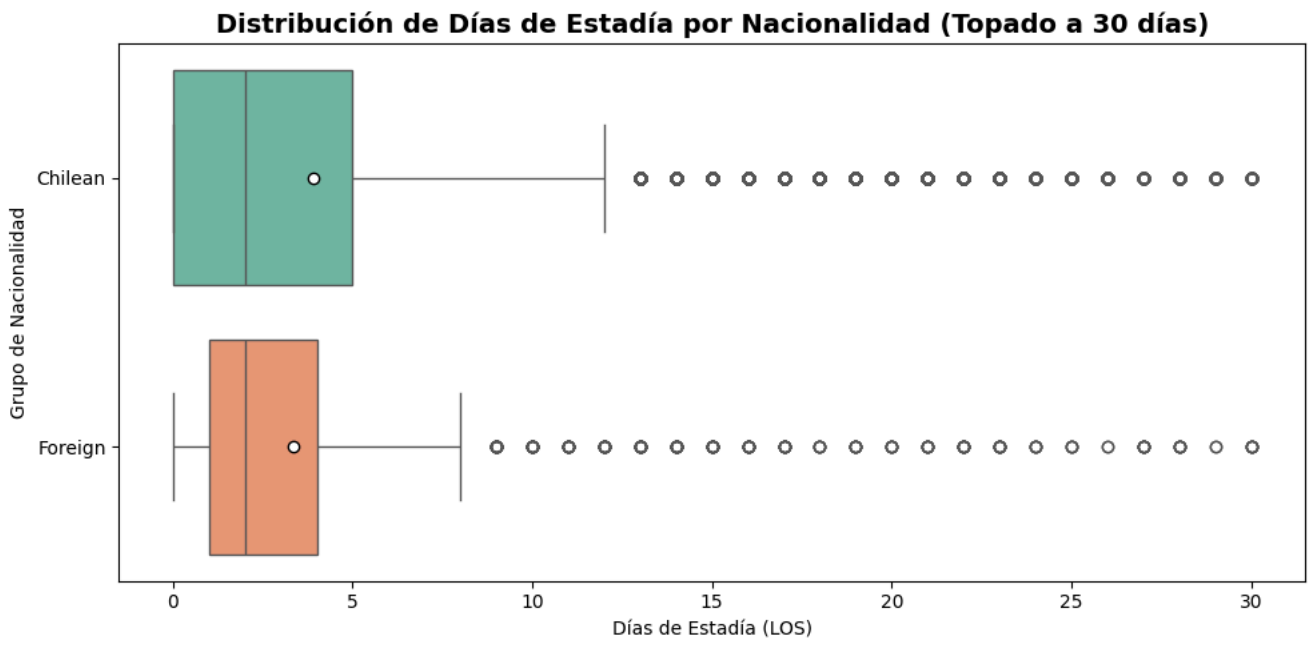

Al analizar los Días de Estadía (LOS) por grupo de nacionalidad, se observa que la **mediana es idéntica para ambos grupos (2.0 días)**. Esto indica que el 50% de las hospitalizaciones, tanto de chilenos como de extranjeros, son de corta duración (2 días o menos).

Sin embargo, existe una diferencia importante en el **promedio** (5,39 días para chilenos frente a 4,25 días para extranjeros). Esta brecha se explica por la presencia de casos atípicos prolongados (como se aprecia en la extensión del boxplot), los cuales son más frecuentes en la población chilena. Este comportamiento es totalmente coherente con el perfil diagnóstico analizado en la sección anterior: la población chilena presenta mayor incidencia de enfermedades crónicas y complejas que requieren recuperaciones extensas, mientras que la hospitalización extranjera está altamente concentrada en maternidad, caracterizada por altas médicas rápidas

B.2.2 Severity distribution

Using `IR_29301_SEVERIDAD` (0 = no severity, 1 = minor, 2 = moderate, 3 = major), plot the severity distribution as a bar chart, split by nationality.

Consult `materials/grd/TablasMaestrasBasesGRD.xlsx` (sheet "Severidad GRD") for the severity labels.

```
print("--- B.2.2: Distribución de Severidad (GRD) ---")

# 1. Mapeamos los números a textos para que se lea bien
mapeo_severidad = {
    "0": "0 - Sin Severidad",
    "1": "1 - Menor",
    "2": "2 - Moderada",
    "3": "3 - Mayor"
}
grd_com["Severidad_Label"] = grd_com["IR_29301_SEVERIDAD"].map(mapeo_severidad) # Creamos una nueva columna con los textos descriptivos de la severidad para usarla en el grá

# 2. GRÁFICO
plt.figure(figsize=(10, 5)) # Creamos el gráfico de barras con seaborn, usando 'hue' para separar por nacionalidad y 'order' para ordenar las categorías de severidad
ax = sns.countplot(
    data=grd_com,
    x="Severidad_Label",
    hue="nat_group",
    order=["0 - Sin Severidad", "1 - Menor", "2 - Moderada", "3 - Mayor"],
    palette="pastel"
)

# Le ponemos números a las barras
for container in ax.containers: # Recorremos cada grupo de barras (Chilenos y Extranjeros) y les ponemos la etiqueta con el número de casos
    ax.bar_label(container, padding=3, fmt='%d') # padding es la distancia entre el número y la barra, fmt='%d' formatea el número como entero

plt.title("Distribución de Severidad por Nacionalidad", fontsize=14, weight='bold') # padding es la distancia entre el número y la barra, fmt='%d' formatea el número como ent
plt.xlabel("Nivel de Severidad") # El título del eje X es "Nivel de Severidad" para que se entienda mejor que los números 0,1,2,3 corresponden a niveles de severidad médica.
plt.ylabel("Cantidad de Egresos") # El título del eje Y es "Cantidad de Egresos" para que se entienda que el número que aparece en cada barra representa la cantidad de egresc
plt.legend(title="Nacionalidad") # La leyenda se titula "Nacionalidad" para que se entienda que los colores representan a Chilenos y Extranjeros.
plt.tight_layout() # Ajustamos el diseño para que no se corte nada
plt.show()

# 3. TABLA NORMALIZADA (El perfil de riesgo)
```

```
print("\n--- Perfil de Severidad Interno (% dentro de cada grupo) ---") # Creamos una tabla que muestra el porcentaje de cada nivel de severidad dentro de los Chilenos y dent

# Contamos los casos
tabla_sev = grd_com.groupby('Severidad_Label')['nat_group'].value_counts().unstack().fillna(0)

# Calculamos los totales POR NACIONALIDAD
total_chilean = tabla_sev['Chilean'].sum()
total_foreign = tabla_sev['Foreign'].sum()

# Armamos la tabla final
tabla_final_sev = pd.DataFrame(index=tabla_sev.index)

# Datos de Chilenos
tabla_final_sev['Chilenos (N°)'] = tabla_sev['Chilean'].astype(int)
tabla_final_sev['Chilenos (%)'] = (tabla_sev['Chilean'] / total_chilean * 100).round(1).astype(str) + "%"

# Datos de Extranjeros
tabla_final_sev['Extranjeros (N°)'] = tabla_sev['Foreign'].astype(int)
tabla_final_sev['Extranjeros (%)'] = (tabla_sev['Foreign'] / total_foreign * 100).round(1).astype(str) + "%"

display.display(tabla_final_sev)
```

```
--- B.2.2: Distribución de Severidad (GRD) ---
```

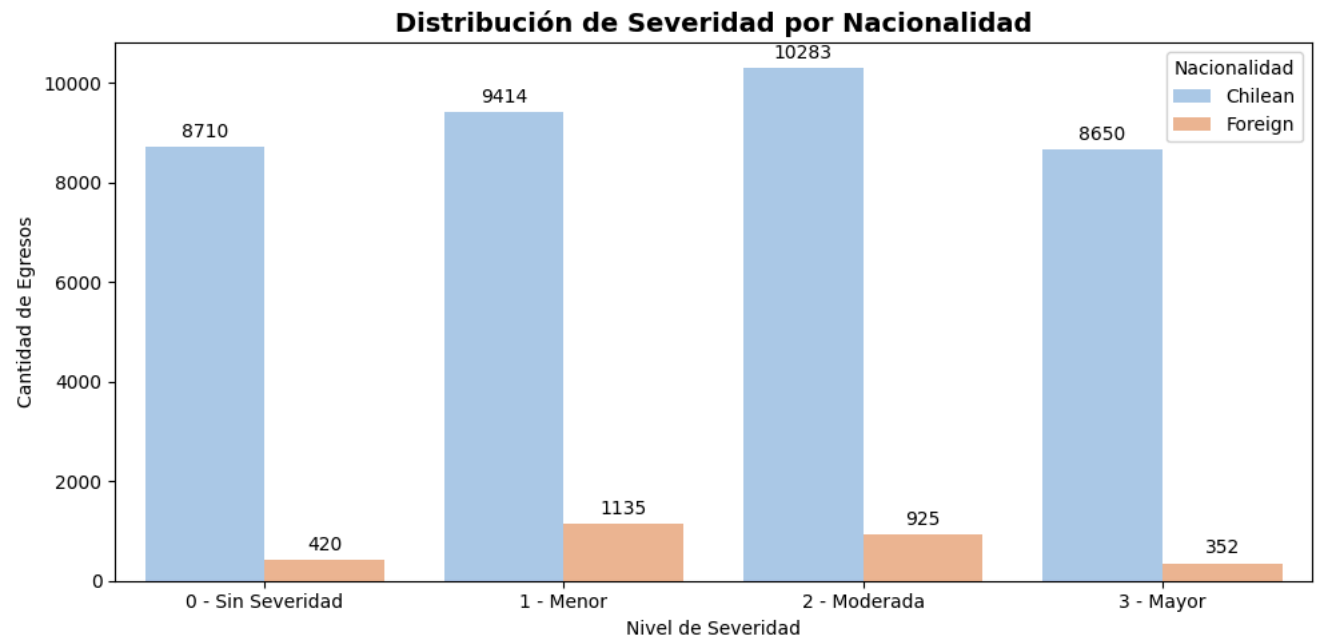


```
--- Perfil de Severidad Interno (% dentro de cada grupo) ---
```

Severidad_Label	Chilenos (N°)	Chilenos (%)	Extranjeros (N°)	Extranjeros (%)
1 - Menor	9414	25.4%	1135	40.1%
2 - Moderada	10283	27.7%	925	32.7%
3 - Mayor	8650	23.3%	352	12.4%

B.2.3 Discharge type

Using `TIPOALTA`, show the distribution of discharge outcomes (e.g., "DOMICILIO", "FALLECIDO", "DERIVACION"). Compute the **in-hospital mortality rate** (share of discharges where `TIPOALTA == "FALLECIDO"`), split by nationality. Present as a small table.

```
print("--- B.2.3: Tipo de Alta y Tasa de Mortalidad ---\n")

# 1. VISIÓN GENERAL: ¿Cómo salen los pacientes del hospital?
print("1. Distribución General de Tipos de Alta en tus comunas:")
# Contamos los tipos de alta y lo mostramos como una tabla ordenada
alta_counts = grd_com["TIPOALTA"].value_counts().reset_index() # Reseteamos el índice para convertirlo en un DataFrame
alta_counts.columns = ["Tipo de Alta", "Cantidad de Egresos"] # Renombramos las columnas para que se vea más profesional
display.display(alta_counts)


# 2. CÁLCULO DE MORTALIDAD POR NACIONALIDAD
print("\n2. Tasa de Mortalidad Intrahospitalaria por Nacionalidad:")

# Agrupamos por nacionalidad y calculamos el volumen y el porcentaje de fallecidos
# La lógica: (x["TIPOALTA"] == "FALLECIDO") nos da 1 si falleció y 0 si no.
# La suma de eso nos da el N° total, y el promedio (mean) nos da la tasa.
mortalidad_df = grd_com.groupby("nat_group").apply(
    lambda x: pd.Series({
        "Total Egresos": len(x), # Total de egresos en ese grupo
        "Fallecidos (N°)": (x["TIPOALTA"] == "FALLECIDO").sum(), # Total de fallecidos en ese grupo
        "Tasa de Mortalidad (%)": ((x["TIPOALTA"] == "FALLECIDO").mean() * 100).round(2) # Tasa de mortalidad en porcentaje
    })
).reset_index() # Reseteamos el índice para convertirlo en un DataFrame normal

# Renombramos la columna para la visualización
mortalidad_df = mortalidad_df.rename(columns={"nat_group": "Nacionalidad"})

# Formateamos el porcentaje para que incluya el símbolo "%"
mortalidad_df["Tasa de Mortalidad (%)"] = mortalidad_df["Tasa de Mortalidad (%)"].astype(str) + "%" # Convertimos a string y añadimos el símbolo

display.display(mortalidad_df) # Mostramos la tabla final de mortalidad por nacionalidad
```

```
--- B.2.3: Tipo de Alta y Tasa de Mortalidad ---

1. Distribución General de Tipos de Alta en tus comunas:
```

	Tipo de Alta	Cantidad de Egresos
0	DOMICILIO	34761
1	HOSPITALIZACIÓN DOMICILIARIA	1754
2	DERIVACIÓN OTRO HOSPITAL DEL SERVICIO	1286
3	FALLECIDO	1093
4	ALTA VOLUNTARIA	392
5	DERIVACIÓN OTRO HOSPITAL DE LA RED NACIONAL	172
6	FUGA DEL PACIENTE	166
7	DERIVACIÓN A OTROS CENTROS (CÁRCEL, HOGAR DE	133
8	DERIVACIÓN INST. PRIVADA (COMPRA DE SERVICIOS	100
9	DERIVACIÓN INST. PRIVADA (VOLUNTARIO)	32

```
2. Tasa de Mortalidad Intrahospitalaria por Nacionalidad:
```

	Nacionalidad	Total Egresos	Fallecidos (N°)	Tasa de Mortalidad (%)
0	Chilean	37057.0	1069.0	2.88%
1	Foreign	2832.0	24.0	0.85%

```
print("--- Tasa de Mortalidad Intrahospitalaria por Comuna y Nacionalidad ---\n")

# 1. Agrupamos por las dos variables: COMUNA y nat_group
mortalidad_segmentada = grd_com.groupby(["COMUNA", "nat_group"]).apply( # Agrupamos los datos por comuna y nacionalidad
    lambda x: pd.Series({ # Para cada grupo (ej: Chilenos en La Granja), calculamos:
        "Total Egresos": len(x), # El total de egresos en ese grupo específico
        "Fallecidos (N°)": (x["TIPOALTA"] == "FALLECIDO").sum(), # El número de fallecidos en ese grupo específico
        "Tasa (%)": ((x["TIPOALTA"] == "FALLECIDO").mean() * 100).round(2) # La tasa de mortalidad en porcentaje para ese grupo específico
    })
).reset_index() # Reseteamos el índice para que COMUNA y nat_group vuelvan a ser columnas normales

# 2. Creamos tablas Pivot para cruzar los datos
# Pivot de Fallecidos
pivot_fallecidos = mortalidad_segmentada.pivot(index="COMUNA", columns="nat_group", values="Fallecidos (N°)") # Pivotamos para tener las comunas como filas y los grupos de na
pivot_fallecidos.columns = ["Chilenos (N° Fallecidos)", "Extranjeros (N° Fallecidos)"] # Renombramos las columnas para que se vea más profesional en la tabla final

# Pivot de Tasas
pivot_tasa = mortalidad_segmentada.pivot(index="COMUNA", columns="nat_group", values="Tasa (%)") # Pivotamos para tener las comunas como filas y los grupos de nacionalidad co
pivot_tasa.columns = ["Chilenos (%)", "Extranjeros (%)"] # Renombramos las columnas para que se vea más profesional en la tabla final

# 3. Unimos ambas tablas para crear una Vista Maestra
tabla_maestra = pd.concat([pivot_fallecidos, pivot_tasa], axis=1) # Concatenamos las dos tablas (fallecidos y tasas) horizontalmente para tener toda la información en una sol

# Le agregamos el símbolo de porcentaje para que se vea perfecto
tabla_maestra["Chilenos (%)"] = tabla_maestra["Chilenos (%)"].astype(str) + "%" # Convertimos la columna de tasas de chilenos a texto y le agregamos el símbolo "%"
tabla_maestra["Extranjeros (%)"] = tabla_maestra["Extranjeros (%)"].astype(str) + "%" # Convertimos la columna de tasas de extranjeros a texto y le agregamos el símbolo "%"

# Ordenamos las columnas para ver Chilenos juntos y Extranjeros juntos
tabla_maestra = tabla_maestra[[ # Reordenamos las columnas para que quede más claro visualmente
    "Chilenos (N° Fallecidos)", "Chilenos (%)", # Primero los datos de chilenos
    "Extranjeros (N° Fallecidos)", "Extranjeros (%)" # Luego los datos de extranjeros
]]

# Quitamos el nombre del índice "COMUNA" para que la tabla quede más limpia visualmente
tabla_maestra.index.name = None

display.display(tabla_maestra)
```

```
--- Tasa de Mortalidad Intrahospitalaria por Comuna y Nacionalidad ---
```

	Chilenos (N° Fallecidos)	Chilenos (%)	Extranjeros (N° Fallecidos)	Extranjeros (%)
LA GRANJA	367.0	2.63%	7.0	0.81%
MACUL	445.0	3.67%	14.0	1.15%
SAN RAMON	257.0	2.34%	3.0	0.4%

B.3 Spatial View (0.5 pts)

B.3.1 Choropleth: hospitalization rate by comuna

Using your Tarea 1 population data, compute a **crude hospitalization rate** (total discharges per 10,000 population) for each of your comunas. Create a choropleth map using `geopandas`.

```
import geopandas as gpd
import IPython.display as display
import matplotlib.patheffects as pe

print("--- B.3.1: Generando Mapa de Tasas de Hospitalización ---")

# 1. CARGAMOS LA TAREA 1 Y LIMPIAMOS TILDES PARA EL CRUCE
ruta_censo = "../Tarea 1/output/tarea1_comuna_summary.csv"
try:
    df_censo = pd.read_csv(ruta_censo)
    # Convertimos a mayúsculas y reemplazamos la Ó por O (para que SAN RAMÓN sea SAN RAMON)
    df_censo["COMUNA_JOIN"] = df_censo["nombre_comuna"].str.upper().str.replace("Ó", "O", regex=False) # Creamos una nueva columna para el cruce que tenga los nombres en mayú
except Exception as e:
    print(f"❌ Error al cargar la Tarea 1: {e}") # Si no se carga la tabla de censo, el resto del código no funcionará porque no tendrá con qué cruzar los datos de egresos.

# 2. Calcular total de egresos por comuna desde la base GRD
egresos_comuna = grd_com.groupby("COMUNA").size().reset_index(name="total_grd") # Contamos el número de egresos por comuna y lo guardamos en una nueva columna llamada "total_

# 3. Cruzar Egresos con Población
df_mapa_data = egresos_comuna.merge(df_censo, left_on="COMUNA", right_on="COMUNA_JOIN") # Hacemos un cruce entre la tabla de egresos por comuna y la tabla del censo usando la

# 4. Calcular la Tasa Cruda (por cada 10.000 habitantes)
df_mapa_data["tasa_10k"] = (df_mapa_data["total_grd"] / df_mapa_data["pop_total"]) * 10000 # La fórmula es: (Número de Egresos / Población Total) * 10.000 para obtener la tas

print("\nTasas calculadas por comuna:") # Mostramos una vista previa de la tabla final que usaremos para el mapa, con solo las columnas clave y redondeando las tasas a 2 deci
display.display(df_mapa_data[["nombre_comuna", "total_grd", "tasa_10k"]].round(2)) # Mostramos solo el nombre de la comuna, el total de egresos y la tasa por cada 10.000 habi

# 5. Cargar el archivo cartográfico (Shapefile)
ruta_shapefile = "../Tarea 1/Mapa comuna/comunas.shp"

try: # Si el shapefile no se carga, el código de dibujo del mapa no funcionará porque no tendrá la geometría de las comunas para dibujar. Por eso es importante manejar esta e
    print(f"\nIntentando dibujar el mapa...") # Avisamos que estamos intentando cargar el mapa, porque a veces tarda un poco y el usuario podría pensar que el programa se cor
    mapa_comunas = gpd.read_file(ruta_shapefile) # Cargamos el shapefile usando geopandas, que es la librería especializada para manejar datos geoespaciales en Python.

    # Usamos el código numérico para un cruce perfecto
```

```
    mapa_comunas["cod_comuna"] = mapa_comunas["cod_comuna"].astype(str) # Convertimos el código de comuna del shapefile a texto para que coincida con el formato de la columna
    df_mapa_data["codigo_comuna_str"] = df_mapa_data["codigo_comuna"].astype(str) # Hacemos lo mismo con la columna de código de comuna del dataframe que creamos, para asegur

    # Cruzamos el mapa
    mapa_final = mapa_comunas.merge(df_mapa_data, left_on="cod_comuna", right_on="codigo_comuna_str") # Hacemos un cruce entre el shapefile (mapa_comunas) y la tabla de datos

    # 6. Dibujar el mapa
    fig, ax = plt.subplots(1, 1, figsize=(10, 10)) # Creamos una figura y un eje para dibujar el mapa. El tamaño de la figura es de 10x10 pulgadas, lo que es un buen tamaño p

    mapa_final.plot( # Dibujamos el mapa usando geopandas
        column="tasa_10k", # La variable que define el color de cada comuna
        cmap="YlOrRd", # Paleta: Amarillo -> Naranja -> Rojo
        legend=True, # Agrega una leyenda automática
        legend_kwds={'label': "Tasa de Hospitalización por cada 10.000 habs", 'shrink': 0.7}, # Personaliza la leyenda
        edgecolor="black", # Color de los bordes de las comunas
        linewidth=0.8, # Grosor de los bordes
        ax=ax # Le decimos que dibuje en el eje que creamos (ax)
    )

    # 7. AGREGAMOS LAS ETIQUETAS PREMIUM
    for idx, row in mapa_final.iterrows():
        # Creamos el texto combinando el nombre y la tasa redondeada a 1 decimal
        texto_etiqueta = f"{row['nombre_comuna']}\n({row['tasa_10k']:.1f})"

        plt.annotate( # Agregamos la anotación en el centroide de cada comuna
            text=texto_etiqueta,  # El texto que queremos mostrar
            xy=(row.geometry.centroid.x, row.geometry.centroid.y), # Coordenadas del centroide de la comuna
            horizontalalignment='center',  # Alineamos el texto horizontalmente al centro
            verticalalignment='center', # Alineamos el texto verticalmente al centro
            fontsize=11,  # Tamaño de letra
            weight='bold', # Negrita para que resalte
            color='black', # Color del texto
            # Este 'path_effects' le pone un borde blanco a las letras para que resalten
            path_effects=[pe.withStroke(linewidth=3, foreground="white")]
        )

    plt.title("Mapa de Tasas de Hospitalización (GRD)\nLa Granja, Macul y San Ramón", fontsize=15, weight='bold')
    plt.axis("off") # Escondemos los ejes (coordenadas) para que parezca mapa
    plt.tight_layout()
    plt.show()

except Exception as e:
    print(f"\n❌ Error al cargar el mapa: {e}")
```

```
--- B.3.1: Generando Mapa de Tasas de Hospitalización ---

Tasas calculadas por comuna:
```

	nombre_comuna	total_grd	tasa_10k
0	La Granja	14803	1321.44
1	Macul	13343	1077.79
2	San Ramón	11743	1545.09

```
Intentando dibujar el mapa...
```

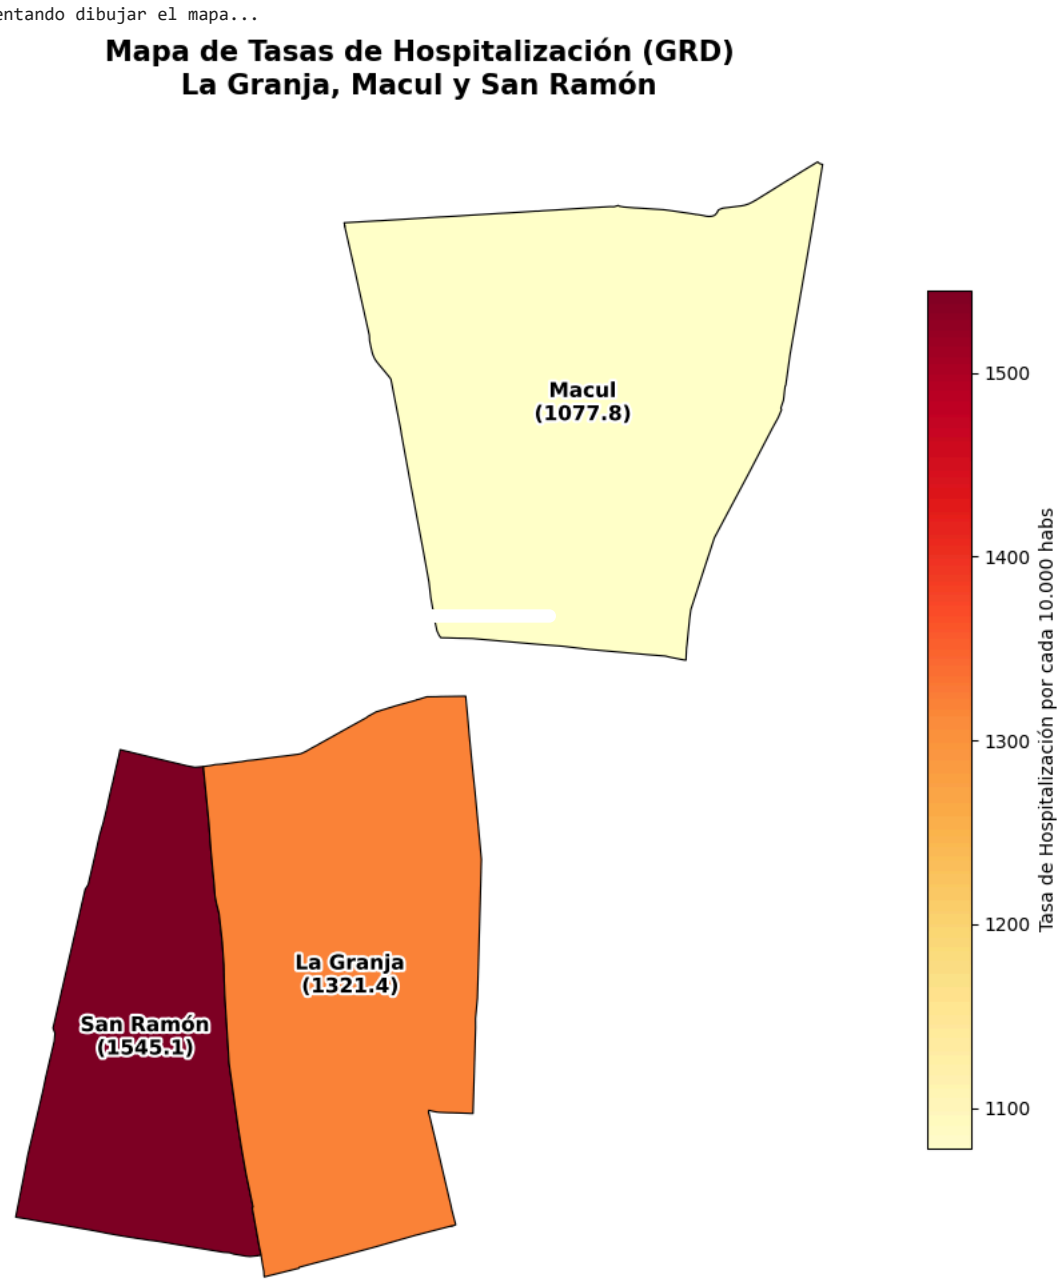

The map should include a title, legend, and comuna labels if legible.

B.4 Comuna-Level GRD Summary Table (0.5 pts)

Build a summary table at the **comuna level** with the following columns:

Column	Description
`codigo_comuna`	Numeric comuna code
`nombre_comuna`	Comuna name
`grd_total`	Total discharges (2022--2024)

Column	Description
`grd_chilean`	Discharges, Chilean nationals
`grd_foreign`	Discharges, foreign nationals
`grd_pct_foreign`	% of discharges by foreign nationals
`grd_mean_los`	Mean length of stay (days)
`grd_mean_los_chilean`	Mean length of stay, Chilean
`grd_mean_los_foreign`	Mean length of stay, foreign
`grd_mean_severity`	Mean severity score
`grd_mortality_rate`	In-hospital mortality rate (% FALLECIDO)
`grd_top3_chapters`	Top 3 ICD-10 chapters (comma-separated)
`grd_rate_per_10k`	Crude hospitalization rate per 10,000 population

For `grd_rate_per_10k`, use `pop_total` from your Tarea 1 summary. You will need to map GRD comuna names back to comuna codes to join with your Census data.

```
import os

print("--- B.4: Generando Comuna-Level GRD Summary Table ---\n")

# 1. CARGAMOS EL CENSO Y CREAMOS DICCIONARIOS PARA BUSCAR LOS DATOS
ruta_censo = "../Tarea 1/output/tarea1_comuna_summary.csv"
try:
    df_censo = pd.read_csv(ruta_censo)
    # Limpiamos tildes para igualar "SAN RAMÓN" con "SAN RAMON"
    df_censo["COMUNA_JOIN"] = df_censo["nombre_comuna"].str.upper().str.replace("Ó", "O", regex=False) # Creamos una nueva columna para el cruce, con el mismo formato que las

    # Creamos diccionarios rápidos para cruzar datos al instante
    dict_poblacion = dict(zip(df_censo["COMUNA_JOIN"], df_censo["pop_total"])) # Población total por comuna
    dict_codigo = dict(zip(df_censo["COMUNA_JOIN"], df_censo["codigo_comuna"])) # Código numérico de comuna
    dict_nombre = dict(zip(df_censo["COMUNA_JOIN"], df_censo["nombre_comuna"])) # Nombre oficial de comuna (con tildes)
except Exception as e:
    print(f"❌ Error al cargar la Tarea 1: {e}")


# 2. DEFINIMOS LA FUNCIÓN CONSTRUCTORA
def build_grd_summary(grupo):
    # SOLUCIÓN AQUÍ: Usamos 'grupo.name' que contiene exactamente
    # el nombre de la comuna que se está procesando en este momento.
    comuna_nombre = str(grupo.name).upper() # Convertimos a mayúsculas para igualar con el formato del censo

    # Cálculos básicos
    total = len(grupo) # Total de egresos en esta comuna
    chilean = len(grupo[grupo["nat_group"] == "Chilean"]) # Total de chilenos
    foreign = len(grupo[grupo["nat_group"] == "Foreign"]) # Total de extranjeros
    pct_foreign = (foreign / total) * 100 if total > 0 else 0 # Porcentaje de extranjeros (cuidado con división por cero)

    # Días de estadía (LOS)
    mean_los = grupo["los"].mean() # Promedio general de días de estadía
    mean_los_ch = grupo[grupo["nat_group"] == "Chilean"]["los"].mean() # Promedio de días para chilenos
    mean_los_fo = grupo[grupo["nat_group"] == "Foreign"]["los"].mean() # Promedio de días para extranjeros

    # Severidad media
    mean_sev = pd.to_numeric(grupo["IR_29301_SEVERIDAD"], errors="coerce").mean() # Convertimos a numérico por si acaso y luego calculamos la media

    # Tasa de Mortalidad (%)
    mortality = (grupo["TIPOALTA"] == "FALLECIDO").mean() * 100 # Porcentaje de egresos que terminaron en fallecimiento

    # Top 3 Capítulos Diagnósticos
    top3_caps = ", ".join(grupo["Capitulo"].value_counts().head(3).index.astype(str)) # Concatenamos los 3 capítulos más comunes en un string separado por comas

    # Población y Tasa de Hospitalización
    poblacion = dict_poblacion.get(comuna_nombre, 1) # Extrae la pob de la Tarea 1
    rate_10k = (total / poblacion) * 10000 # Calculamos la tasa por cada 10.000 habitantes (cuidado con división por cero, por eso el default es 1)

    # Retornamos la fila compilada
    return pd.Series({
        "codigo_comuna": dict_codigo.get(comuna_nombre, ""), # Extrae el código de la comuna desde la Tarea 1
        "nombre_comuna": dict_nombre.get(comuna_nombre, comuna_nombre), # Extrae el nombre oficial de la comuna desde la Tarea 1, si no lo encuentra, deja el nombre del grupo
        "grd_total": total, # Total de egresos hospitalarios en esta comuna
        "grd_chilean": chilean, # Total de egresos de pacientes chilenos
        "grd_foreign": foreign, # Total de egresos de pacientes extranjeros
        "grd_pct_foreign": pct_foreign, # Porcentaje de egresos que son extranjeros
        "grd_mean_los": mean_los, # Promedio general de días de estadía
        "grd_mean_los_chilean": mean_los_ch, # Promedio de días de estadía para pacientes chilenos
        "grd_mean_los_foreign": mean_los_fo, # Promedio de días de estadía para pacientes extranjeros
        "grd_mean_severity": mean_sev, # Promedio de severidad (GRD) en esta comuna
        "grd_mortality_rate": mortality, # Tasa de mortalidad intrahospitalaria en esta comuna
        "grd_top3_chapters": top3_caps, # Los 3 capítulos diagnósticos más comunes en esta comuna
        "grd_rate_per_10k": rate_10k # Tasa de hospitalización por cada 10.000 habitantes
    })

# 3. APLICAMOS LA FUNCIÓN PARA CREAR LA TABLA FINAL
grd_summary = grd_com.groupby("COMUNA").apply(build_grd_summary).reset_index(drop=True) # Reseteamos el índice para que quede limpio (la comuna ya está en una columna dentro

# 4. MOSTRAMOS LA TABLA EN PANTALLA
print("Vista Previa de la Tabla Final (Redondeada a 2 decimales):") # Redondeamos a 2 decimales para que se vea más limpia en pantalla, pero el archivo CSV guardará los númer
display.display(grd_summary.round(2))

# 5. GUARDAMOS EL ARCHIVO CSV
os.makedirs("output", exist_ok=True) # Crea la carpeta output si no existe
ruta_salida = "output/tarea2_grd_summary.csv" # Guardamos la tabla final en un archivo CSV sin el índice (index=False)
grd_summary.to_csv(ruta_salida, index=False)

print(f"\n¡ÉXITO! 🎉 La tabla final se ha guardado correctamente en: '{ruta_salida}'")
```

```
--- B.4: Generando Comuna-Level GRD Summary Table ---

Vista Previa de la Tabla Final (Redondeada a 2 decimales):
```

	codigo_comuna	nombre_comuna	grd_total	grd_chilean	grd_foreign	grd_pct_foreign	grd_mean_los	grd_mean_los_chilean	grd_mean_los_foreign	grd_mean_severity	grd_mortalit
0	13111	La Granja	14803	13943	860	5.81	5.39	5.44	4.63	1.48	
1	13118	Macul	13343	12128	1215	9.11	5.52	5.67	4.03	1.57	
2	13131	San Ramón	11743	10986	757	6.45	4.97	5.02	4.19	1.45	

```
¡ÉXITO! 🎉 La tabla final se ha guardado correctamente en: 'output/tarea2_grd_summary.csv'
```

Display the table in your notebook and save it as CSV.

Deliverables

Submit on **Canvas** before class on Thursday, April 16:

1. **PDF export** of your Colab notebook (File > Print > Save as PDF, or File > Download > Download .pdf).
2. **Link to your GitHub repository** (the notebook and both summary CSVs should be committed).

Your notebook must include:

- Markdown cells explaining each step and interpreting results
- All code cells executed with visible output
- The following visualizations:
  - ENO notifications over time, by nationality (Part A.1)
  - Top diseases bar chart (Part A.2.1)
  - Disease profile by nationality (Part A.2.2)
  - Age-group distribution for top disease (Part A.2.3)
  - Top diagnostic chapters and top specific diagnoses (Part B.1)
  - Diagnostic chapters by nationality (Part B.1.3)
  - Length of stay distribution by nationality (Part B.2.1)